MTH 8302 - Modèles de Régression et d'Analyse de Variance

Leçon 7 : Régression Linéaire Multiple

Polytechnique Montréal - Hiver 2026

Chiheb Trabelsi

25 Mars 2026

Table des Matières

1. Régression Linéaire Multiple
2. Décomposition de la Variabilité Totale
3. ANOVA en Régression Linéaire Multiple
4. Exercice : Boston Housing Prices Dataset
5. Intervalle de Confiance et Intervalle de Prédiction
6. Annexe

Régression Linéaire Multiple

Pourquoi passer à la régression multiple ?

- En régression linéaire simple, on modélise la variable réponse Y à l'aide d'une seule variable explicative.
- En pratique, plusieurs facteurs influencent souvent simultanément la variable réponse.
- La régression linéaire multiple permet de modéliser l'effet conjoint de plusieurs variables explicatives sur Y.
- Elle généralise donc naturellement la régression linéaire simple.

Idée générale

On cherche à expliquer une variable réponse Y à l'aide de plusieurs variables explicatives $X_1, X_2, \ldots, X_p$.

Modèle de régression linéaire multiple

Expression du modèle

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \varepsilon$$

- Y : variable réponse ;
- $X_1, X_2, \ldots, X_p$: variables explicatives ;
- β_0 : intercept ;
- $\beta_1, \ldots, \beta_p$: coefficients de régression ;
- ε : erreur aléatoire.

Interprétation des coefficients

Idée clé

Le coefficient β_j mesure la variation attendue de Y lorsque X_j augmente d'une unité, **en gardant les autres variables explicatives constantes**.

Attention

En régression multiple, un coefficient représente un **effet partiel** et non un effet brut.

Exemple

Si

$$Y = \beta_0 + \beta_1(\text{superficie}) + \beta_2(\text{âge}) + \beta_3(\text{nombre de pièces}) + \varepsilon,$$

alors β_1 représente l'effet de la superficie sur Y, à âge et nombre de pièces fixés.

Formulation matricielle

Écriture compacte du modèle

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

- $\mathbf{Y} \in \mathbb{R}^n$: vecteur des réponses ;
- $\mathbf{X} \in \mathbb{R}^{n \times (p+1)}$: matrice de conception ;
- $\boldsymbol{\beta} \in \mathbb{R}^{p+1}$: vecteur des coefficients ;
- $\boldsymbol{\varepsilon} \in \mathbb{R}^n$: vecteur des erreurs.

Exemple de matrice de conception

Supposons $n = 5$ observations et $p = 2$ variables explicatives.

$$\mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{21} & x_{22} \\ 1 & x_{31} & x_{32} \\ 1 & x_{41} & x_{42} \\ 1 & x_{51} & x_{52} \end{bmatrix}, \qquad \mathbf{Y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \end{bmatrix}$$

- chaque ligne de $\mathbf{X}$ correspond à une observation ;
- chaque colonne (sauf la première) correspond à une variable explicative ;
- la première colonne de 1 permet d'inclure l'intercept β_0.

Mini-exercice

Considérons le modèle

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

et la matrice de conception

$$\mathbf{X} = \begin{bmatrix} 1 & 2 & 5 \\ 1 & 3 & 7 \\ 1 & 4 & 6 \end{bmatrix}.$$

Questions

1. Combien y a-t-il d'observations ?
2. Combien y a-t-il de variables explicatives ?
3. Pourquoi la première colonne contient-elle uniquement des 1 ?

Mini-exercice : solution

Réponses

1. Il y a 3 observations, car la matrice $\mathbf{X}$ possède 3 lignes.
2. Il y a 2 variables explicatives, car en dehors de la première colonne, on observe 2 colonnes correspondant à X_1 et X_2.
3. La première colonne de 1 permet d'inclure l'intercept β_0 dans l'écriture matricielle.

À retenir

Si le modèle contient un intercept, la matrice de conception comporte une première colonne de 1.

Résumé du bloc

- La régression multiple généralise la régression simple à plusieurs variables explicatives.
- Chaque coefficient β_j représente un **effet partiel**.
- Le modèle s'écrit aussi sous forme matricielle :

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

- La matrice $\mathbf{X}$ regroupe les observations et les variables explicatives.

Hypothèses essentielles du modèle

- **Linéarité :**

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon$$

- **Indépendance des erreurs :**

$$\mathrm{Cov}(\varepsilon_i, \varepsilon_j) = 0 \quad \text{pour } i \neq j$$

- **Homoscédasticité :**

$$\mathrm{Var}(\varepsilon_i) = \sigma^2$$

- **Normalité des erreurs :**

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

- **Additivité :** Les effets des différentes variables explicatives sur la variable dépendante sont additifs.
- **Absence de multicolinéarité parfaite :** les variables explicatives ne doivent pas être linéairement dépendantes.

Pourquoi ces hypothèses sont-elles importantes ?

- Elles permettent de donner un cadre mathématique au modèle.
- Certaines hypothèses sont surtout importantes pour l'**estimation**.
- D'autres sont surtout importantes pour l'**inférence statistique**.

Exemples

- L'absence de multicolinéarité parfaite est essentielle pour obtenir un estimateur MCO sous forme fermée.
- La normalité des erreurs est surtout utile pour justifier certains tests et intervalles de confiance.

Qu'est-ce qu'un modèle linéaire ?

Idée clé

Un modèle est dit **linéaire** s'il est linéaire par rapport aux coefficients $\beta_0, \beta_1, \ldots, \beta_p$.

Attention

Un modèle peut être non linéaire en variables explicatives tout en restant linéaire en coefficients.

Exemples de modèles linéaires

- **Exemple 1 :**

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i$$

Ce modèle est linéaire en les coefficients.

- **Exemple 2 :**

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 (X_{1i} X_{2i}) + \varepsilon_i$$

Ce modèle est aussi linéaire en les coefficients.

- **Exemple 3 :**

$$Y_i = \beta_0 + \beta_1 \sqrt{X_i} + \varepsilon_i$$

Ce modèle reste linéaire en les coefficients.

Exemple d'un modèle non linéaire

Exemple

$$Y_i = \frac{\beta_0}{1 + e^{-(\beta_1 X_{1i} + \beta_2 X_{2i})}} + \varepsilon_i$$

- Ici, les coefficients apparaissent à l'intérieur d'une transformation non linéaire.
- Le modèle n'est donc pas linéaire en les coefficients.

Mini-exercice : modèle linéaire ou non ?

Pour chacun des modèles suivants, déterminer s'il est linéaire en les coefficients.

1. $$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i$$

2. $$Y_i = \beta_0 + \beta_1 \sin(X_i) + \varepsilon_i$$

3. $$Y_i = \beta_0 + \beta_1^2 X_i + \varepsilon_i$$

4. $$Y_i = \beta_0 e^{\beta_1 X_i} + \varepsilon_i$$

Mini-exercice : solution

Réponses

1. $$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i$$

   Linéaire, car les coefficients apparaissent au premier degré.

2. $$Y_i = \beta_0 + \beta_1 \sin(X_i) + \varepsilon_i$$

   Linéaire, car $\sin(X_i)$ joue simplement le rôle d'une variable explicative transformée.

3. $$Y_i = \beta_0 + \beta_1^2 X_i + \varepsilon_i$$

   Non linéaire, car β_1 apparaît au carré.

4. $$Y_i = \beta_0 e^{\beta_1 X_i} + \varepsilon_i$$

   Non linéaire, car β_1 apparaît dans une exponentielle.

À retenir avant l'estimation

- Les hypothèses du modèle jouent un rôle important dans l'estimation et l'inférence.
- Un modèle linéaire est un modèle linéaire en coefficients.
- Les variables explicatives peuvent être transformées sans que le modèle cesse d'être linéaire.

Prochaine étape

Nous allons maintenant estimer les coefficients du modèle à l'aide de la méthode des **moindres carrés ordinaires (MCO)**.

Exercice : comment estimer les coefficients ?

On considère le modèle de régression linéaire multiple

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

On observe les données $\mathbf{y}$, mais les coefficients $\boldsymbol{\beta}$ sont inconnus.

Problème

Comment choisir $\boldsymbol{\beta}$ de sorte que le modèle s'ajuste le mieux possible aux données observées ?

Idée

Nous allons chercher les coefficients qui rendent les **résidus** aussi petits que possible.

Exercice : définir les résidus

Pour une observation i, la valeur prédite par le modèle est

$$\hat{y}_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}.$$

Le résidu associé à l'observation i est alors

$$e_i = y_i - \hat{y}_i.$$

Question

Pourquoi ne pas simplement minimiser la somme des résidus

$$\sum_{i=1}^{n} e_i \, ?$$

Exercice : pourquoi utiliser les carrés ?

Réponse

Si l'on additionne directement les résidus, les valeurs positives et négatives peuvent se compenser.

Idée des MCO

On minimise donc la somme des carrés des résidus :

$$\sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2.$$

Problème d'optimisation

$$\hat{\boldsymbol{\beta}} = \arg\min_{\boldsymbol{\beta}} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2.$$

Exercice : écrire le problème en notation matricielle

Nous avons vu que

$$\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}, \qquad \mathbf{X} = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{bmatrix}.$$

Question

Comment écrire

$$\sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

en notation matricielle ?

Exercice : solution matricielle

Le vecteur des résidus s'écrit

$$\mathbf{e} = \mathbf{y} - \mathbf{X}\boldsymbol{\beta}.$$

La somme des carrés des résidus devient alors

$$\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2.$$

On peut aussi l'écrire sous la forme

$$(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}).$$

Problème MCO

$$\hat{\boldsymbol{\beta}} = \arg\min_{\boldsymbol{\beta}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2.$$

Rappel : gradients et Hessiennes

Pourquoi ce rappel ?

Pour minimiser une fonction de plusieurs variables, on cherche généralement :

- les points où le **gradient** est nul ;
- puis on vérifie la nature du point critique à l'aide de la **Hessienne**.

- Le gradient regroupe les dérivées partielles premières.
- La Hessienne regroupe les dérivées partielles secondes.
- Si la Hessienne est définie positive, on a un minimum.

MCO et propriétés de l'estimateur MCO

MCO : dérivation par exercices QCM

QCM : développement de la fonction coût

On considère la fonction coût

$$J(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}).$$

Question

Laquelle des expressions suivantes correspond au développement correct de $J(\boldsymbol{\beta})$?

A. $\mathbf{y}^\top\mathbf{y} - \mathbf{y}^\top\mathbf{X}\boldsymbol{\beta} - \boldsymbol{\beta}^\top\mathbf{X}^\top\mathbf{y} + \boldsymbol{\beta}^\top\mathbf{X}^\top\mathbf{X}\boldsymbol{\beta}$

B. $\mathbf{y}^\top\mathbf{y} + \mathbf{y}^\top\mathbf{X}\boldsymbol{\beta} - \boldsymbol{\beta}^\top\mathbf{X}^\top\mathbf{X}\boldsymbol{\beta}$

C. $\mathbf{y}^\top\mathbf{y} - 2\mathbf{y}^\top\mathbf{X}\boldsymbol{\beta} + \mathbf{X}^\top\mathbf{X}$

D. $\mathbf{y}^\top\mathbf{y} - \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\beta}^\top\mathbf{X}^\top\mathbf{X}\boldsymbol{\beta}$

QCM : corrigé du développement

Bonne réponse : A

$$J(\boldsymbol{\beta}) = \mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top \mathbf{X}\boldsymbol{\beta} - \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{y} + \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}$$

Pourquoi ?

- On utilise la distributivité du produit matriciel.
- On remarque que
$$(\mathbf{X}\boldsymbol{\beta})^\top \mathbf{y} = \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{y}.$$
- Les deux termes du milieu $\mathbf{y}^\top \mathbf{X}\boldsymbol{\beta}$ et $\boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{y}$ sont des scalaires égaux.

Forme simplifiée

On peut donc écrire

$$J(\boldsymbol{\beta}) = \mathbf{y}^\top \mathbf{y} - 2\boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{y} + \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}.$$

QCM : calcul du gradient

On part maintenant de

$$J(\boldsymbol{\beta}) = \mathbf{y}^\top \mathbf{y} - 2\boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{y} + \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}.$$

Question

Quel est le gradient de $J(\boldsymbol{\beta})$ par rapport à $\boldsymbol{\beta}$?

A.

$$\nabla_{\boldsymbol{\beta}} J(\boldsymbol{\beta}) = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}$$

B.

$$\nabla_{\boldsymbol{\beta}} J(\boldsymbol{\beta}) = 2\mathbf{y} - 2\mathbf{X}\boldsymbol{\beta}$$

C.

$$\nabla_{\boldsymbol{\beta}} J(\boldsymbol{\beta}) = -2\mathbf{X}\mathbf{y} + 2\mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}$$

D.

$$\nabla_{\boldsymbol{\beta}} J(\boldsymbol{\beta}) = \mathbf{X}^\top \mathbf{X}\boldsymbol{\beta} - \mathbf{X}^\top \mathbf{y}$$

QCM : corrigé du gradient

Bonne réponse : A

$$\nabla_{\boldsymbol{\beta}} J(\boldsymbol{\beta}) = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}$$

Rappels utilisés

- $$\nabla_{\boldsymbol{\beta}}(\mathbf{a}^\top \boldsymbol{\beta}) = \mathbf{a}$$
- $$\nabla_{\boldsymbol{\beta}}(\boldsymbol{\beta}^\top A \boldsymbol{\beta}) = 2A\boldsymbol{\beta} \quad \text{si } A \text{ est symétrique}$$
- Ici, $A = \mathbf{X}^\top \mathbf{X}$, qui est symétrique.

QCM : équation normale

Pour trouver un point critique, on impose

$$\nabla_{\boldsymbol{\beta}} J(\boldsymbol{\beta}) = \mathbf{0}.$$

Question

Laquelle des équations suivantes obtient-on alors ?

A.
$$\mathbf{X}\mathbf{X}^\top \boldsymbol{\beta} = \mathbf{X}\mathbf{y}$$

B.
$$\mathbf{X}^\top \mathbf{X}\boldsymbol{\beta} = \mathbf{X}^\top \mathbf{y}$$

C.
$$\mathbf{X}^\top \boldsymbol{\beta} = \mathbf{y}$$

D.
$$\mathbf{X}\boldsymbol{\beta} = \mathbf{X}^\top \mathbf{y}$$

QCM : corrigé de l'équation normale

Bonne réponse : B

En annulant le gradient,

$$-2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X}\boldsymbol{\beta} = \mathbf{0},$$

d'où

$$\mathbf{X}^\top \mathbf{X}\boldsymbol{\beta} = \mathbf{X}^\top \mathbf{y}.$$

Nom

Cette relation est appelée l'**équation normale**.

QCM : estimateur MCO

Supposons maintenant que $\mathbf{X}^\top \mathbf{X}$ soit inversible.

Question

Quelle est alors l'expression correcte de l'estimateur MCO ?

A.
$$\hat{\boldsymbol{\beta}} = \mathbf{X}^\top (\mathbf{X}\mathbf{X}^\top)^{-1} \mathbf{y}$$

B.
$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

C.
$$\hat{\boldsymbol{\beta}} = \mathbf{X}^{-1} \mathbf{y}$$

D.
$$\hat{\boldsymbol{\beta}} = (\mathbf{X}\mathbf{X}^\top)^{-1} \mathbf{y}$$

QCM : corrigé de l'estimateur MCO

Bonne réponse : B

Si $\mathbf{X}^\top \mathbf{X}$ est inversible, on multiplie l'équation normale à gauche par $(\mathbf{X}^\top \mathbf{X})^{-1}$, ce qui donne

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Conclusion

Cet estimateur est l'**estimateur des moindres carrés ordinaires (MCO)**.

QCM : Hessienne et nature du point critique

On a obtenu

$$\nabla_{\boldsymbol{\beta}} J(\boldsymbol{\beta}) = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}.$$

Question

Quelle est la Hessienne de $J(\boldsymbol{\beta})$ et que permet-elle de conclure ?

A. $\nabla^2_{\boldsymbol{\beta}} J(\boldsymbol{\beta}) = 2\mathbf{X}^\top \mathbf{X}$ et si $\mathbf{X}^\top \mathbf{X}$ est définie positive, alors le point critique est un minimum global unique.

B. $\nabla^2_{\boldsymbol{\beta}} J(\boldsymbol{\beta}) = \mathbf{X}^\top \mathbf{X}$ et cela montre seulement que le point critique est un maximum local.

C. $\nabla^2_{\boldsymbol{\beta}} J(\boldsymbol{\beta}) = 2\mathbf{X}\mathbf{X}^\top$ et cela montre que toute solution est optimale.

D. $\nabla^2_{\boldsymbol{\beta}} J(\boldsymbol{\beta}) = 2\mathbf{I}$ et cela ne dépend pas des données.

QCM : corrigé de la Hessienne

Bonne réponse : A

$$\nabla^2_{\boldsymbol{\beta}} J(\boldsymbol{\beta}) = 2\mathbf{X}^\top \mathbf{X}.$$

- La matrice $\mathbf{X}^\top \mathbf{X}$ est symétrique.
- Elle est positive semi-définie.
- Si elle est définie positive, alors $J(\boldsymbol{\beta})$ est strictement convexe.
- La solution obtenue est alors l'unique minimum global.
- **Consulter l'annexe pour les propriétés de $\mathbf{G} = \mathbf{X}^\mathrm{T}\mathbf{X}$**

À retenir

- Les MCO consistent à minimiser la somme des carrés des résidus.
- La fonction coût s'écrit

$$J(\boldsymbol{\beta}) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2.$$

- L'annulation du gradient mène à l'équation normale

$$\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}.$$

- Si $\mathbf{X}^\top \mathbf{X}$ est inversible, alors

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

- La Hessienne permet de confirmer qu'il s'agit bien d'un minimum.

Propriétés de l'estimateur MCO

QCM : biais de l'estimateur MCO

On suppose le modèle

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \qquad \mathbb{E}[\boldsymbol{\varepsilon}] = \mathbf{0},$$

et l'estimateur MCO

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Question

Quelle expression obtient-on en remplaçant $\mathbf{y}$ dans la formule de $\hat{\boldsymbol{\beta}}$?

A. $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}\boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon}$

B. $\hat{\boldsymbol{\beta}} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$

C. $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \boldsymbol{\beta} + \mathbf{X}^\top \boldsymbol{\varepsilon}$

D. $\hat{\boldsymbol{\beta}} = \boldsymbol{\beta} + \mathbf{X}\boldsymbol{\varepsilon}$

QCM : corrigé du remplacement

Bonne réponse : A

En remplaçant $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ dans

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y},$$

on obtient

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}).$$

En distribuant,

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}\boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon}.$$

Comme

$$(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} = \mathbf{I},$$

on obtient finalement

$$\hat{\boldsymbol{\beta}} = \boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon}.$$

QCM : espérance de l'estimateur

À partir de

$$\hat{\boldsymbol{\beta}} = \boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon},$$

et du fait que

$$\mathbb{E}[\boldsymbol{\varepsilon}] = \mathbf{0},$$

déterminons $\mathbb{E}[\hat{\boldsymbol{\beta}}]$.

Question

Quelle affirmation est correcte ?

A. $\mathbb{E}[\hat{\boldsymbol{\beta}}] = \mathbf{0}$

B. $\mathbb{E}[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta}$

C. $\mathbb{E}[\hat{\boldsymbol{\beta}}] = (\mathbf{X}^\top \mathbf{X})^{-1} \boldsymbol{\beta}$

D. $\mathbb{E}[\hat{\boldsymbol{\beta}}] = \mathbf{X}\boldsymbol{\beta}$

QCM : corrigé sur le biais

Bonne réponse : B

En prenant l'espérance,

$$\mathbb{E}[\hat{\boldsymbol{\beta}}] = \mathbb{E}\left[\boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon}\right].$$

Comme $\boldsymbol{\beta}$ est constant,

$$\mathbb{E}[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbb{E}[\boldsymbol{\varepsilon}].$$

Or

$$\mathbb{E}[\boldsymbol{\varepsilon}] = \mathbf{0},$$

donc

$$\mathbb{E}[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta}.$$

Conclusion

L'estimateur MCO est **sans biais**.

QCM : variance de l'estimateur MCO

On repart de

$$\hat{\boldsymbol{\beta}} = \boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon}.$$

Question

Quelle expression donne correctement la variance de $\hat{\boldsymbol{\beta}}$?

A.

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \mathrm{Var}(\boldsymbol{\beta}) + \mathrm{Var}(\boldsymbol{\varepsilon})$$

B.

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathrm{Var}(\boldsymbol{\varepsilon}) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1}$$

C.

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 \mathbf{X}^\top \mathbf{X}$$

D.

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 \mathbf{X} \mathbf{X}^\top$$

QCM : corrigé de la formule de variance

Bonne réponse : B

Comme $\boldsymbol{\beta}$ est constant,

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \mathrm{Var}\big((\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\boldsymbol{\varepsilon}\big)\,.$$

Si A est une matrice constante, alors

$$\mathrm{Var}(A\boldsymbol{\varepsilon}) = A\,\mathrm{Var}(\boldsymbol{\varepsilon})\,A^\top.$$

Ici,

$$A = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top,$$

donc

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathrm{Var}(\boldsymbol{\varepsilon})\mathbf{X}\left[(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\right]^\top.$$

Comme

$$\left[(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\right]^\top = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1},$$

on obtient

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathrm{Var}(\boldsymbol{\varepsilon})\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}.$$

QCM : simplification sous homoscédasticité

Supposons maintenant que

$$\mathrm{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}.$$

Question

Quelle simplification obtient-on alors ?

A.
$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$$

B.
$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 \mathbf{X}^\top \mathbf{X}$$

C.
$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 \mathbf{I}$$

D.
$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}^\top \mathbf{X})^{-1}$$

QCM : corrigé de la variance finale

Bonne réponse : A

En remplaçant $\mathrm{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}$, on obtient

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\sigma^2 \mathbf{I}) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1}.$$

Donc

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1}.$$

Comme

$$\mathbf{X}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} = \mathbf{I},$$

on obtient

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}.$$

Interprétation

La variance des estimateurs dépend directement de la matrice $(\mathbf{X}^\top \mathbf{X})^{-1}$.

QCM : interprétation de la variance

Sachant que

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1},$$

quelle conclusion est la plus pertinente ?

A. Plus $\mathbf{X}^\top\mathbf{X}$ est mal conditionnée, plus la variance des coefficients peut devenir grande.
B. La variance de $\hat{\boldsymbol{\beta}}$ ne dépend jamais des variables explicatives.
C. La variance de $\hat{\boldsymbol{\beta}}$ est toujours égale à $\sigma^2\mathbf{I}$.
D. La variance disparaît si $n > p$.

QCM : corrigé d'interprétation

Bonne réponse : A

La formule

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}$$

montre que la précision des estimateurs dépend de la géométrie de la matrice de conception $\mathbf{X}$.

- Si $\mathbf{X}^\top\mathbf{X}$ est proche d'être singulière, son inverse peut contenir de très grandes valeurs.
- Cela augmente la variance des coefficients estimés.
- Les estimations deviennent alors moins stables.

Transition

Ceci nous conduira naturellement à la question de la **multicolinéarité** et du **nombre de conditionnement**.

À retenir

- L'estimateur MCO peut s'écrire

$$\hat{\boldsymbol{\beta}} = \boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon}.$$

- Son espérance vaut

$$\mathbb{E}[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta},$$

  donc il est **sans biais**.
- Sous l'hypothèse $\mathrm{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}$, on a

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}.$$

- La variance des coefficients dépend fortement de la structure de $\mathbf{X}$.

Propriétés de l'estimateur MCO

QCM : multicolinéarité parfaite

On rappelle que l'estimateur MCO est donné par

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y},$$

lorsque $\mathbf{X}^\top \mathbf{X}$ est inversible.

Question

Que signifie la **multicolinéarité parfaite** ?

A. Toutes les variables explicatives sont indépendantes.
B. Au moins une variable explicative est combinaison linéaire exacte des autres.
C. Les erreurs du modèle sont corrélées.
D. La variance des erreurs est constante.

QCM : corrigé sur la multicolinéarité parfaite

Bonne réponse : B

Il y a **multicolinéarité parfaite** lorsqu'au moins une colonne de $\mathbf{X}$ peut s'écrire comme combinaison linéaire exacte des autres colonnes.

- Les colonnes de $\mathbf{X}$ sont alors linéairement dépendantes.
- La matrice $\mathbf{X}$ n'est pas de plein rang.
- Par conséquent, $\mathbf{X}^\top\mathbf{X}$ n'est pas inversible.

Conclusion

Dans ce cas, la formule usuelle de l'estimateur MCO ne peut pas être appliquée.

QCM : multicolinéarité forte mais non parfaite

Question

Que se passe-t-il lorsque les variables explicatives sont **très corrélées** sans être exactement dépendantes ?

A. Aucun effet particulier : l'estimation reste toujours parfaitement stable.

B. $\mathbf{X}^\top \mathbf{X}$ peut devenir mal conditionnée, ce qui rend les coefficients instables.

C. Les résidus deviennent automatiquement nuls.

D. Le modèle cesse d'être linéaire.

QCM : corrigé sur la multicolinéarité forte

Bonne réponse : B

Même sans dépendance linéaire exacte, une forte corrélation entre variables explicatives peut rendre $\mathbf{X}^\top\mathbf{X}$ **mal conditionnée**.

- L'inverse $(\mathbf{X}^\top\mathbf{X})^{-1}$ peut alors contenir de très grandes valeurs.
- Cela augmente la variance des coefficients estimés.
- Les coefficients peuvent beaucoup changer lorsque les données changent légèrement.

QCM : conséquence sur la variance

On a montré que

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}.$$

Question

Quelle conséquence cette formule met-elle en évidence ?

A. La variance des coefficients ne dépend que de σ^2.
B. Une matrice $\mathbf{X}^\top\mathbf{X}$ mal conditionnée peut entraîner une grande variance des estimateurs.
C. La multicolinéarité réduit toujours la variance des estimateurs.
D. Si n est grand, la multicolinéarité n'a plus aucun effet.

QCM : corrigé sur la variance

Bonne réponse : B

La formule

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}$$

montre directement que la stabilité des estimateurs dépend de la matrice $\mathbf{X}$.

Interprétation

Si $\mathbf{X}^\top\mathbf{X}$ est proche d'être singulière, son inverse peut devenir très grand, ce qui augmente fortement la variance des coefficients estimés.

QCM : nombre de conditionnement

Question

Que mesure principalement le **nombre de conditionnement** d'une matrice ?

A. Le nombre d'observations dans l'échantillon.
B. Le degré de sensibilité de la solution à de petites perturbations des données.
C. Le nombre de coefficients du modèle.
D. La moyenne des valeurs propres de la matrice.

QCM : corrigé sur le nombre de conditionnement

Bonne réponse : B

Le nombre de conditionnement mesure la **sensibilité numérique** d'un problème : de petites perturbations dans les données peuvent produire de grands changements dans la solution.

Dans notre contexte

Si $\mathbf{X}^\top \mathbf{X}$ a un grand nombre de conditionnement, alors l'estimation de $\hat{\boldsymbol{\beta}}$ peut être numériquement instable.

Définition du nombre de conditionnement

- Pour analyser le conditionnement et la sensibilité numérique de la matrice de Gram
$$\mathbf{G} = \mathbf{X}^\top \mathbf{X},$$
on introduit le **nombre de conditionnement**.
- Le nombre de conditionnement de la matrice $\mathbf{G} = \mathbf{X}^\top \mathbf{X}$ permet de mesurer la sensibilité des solutions du système
$$\hat{\boldsymbol{\beta}} = \mathbf{G}^{-1}\mathbf{X}^\top \mathbf{y}$$
aux perturbations des données.
- Le nombre de conditionnement d'une matrice $\mathbf{G}$ est défini par
$$\kappa(\mathbf{G}) = \left| \frac{\lambda_{\max}(\mathbf{G})}{\lambda_{\min}(\mathbf{G})} \right|,$$
où
  - $\lambda_{\max}(\mathbf{G})$ est la plus grande valeur propre de $\mathbf{G}$,
  - $\lambda_{\min}(\mathbf{G})$ est la plus petite valeur propre de $\mathbf{G}$.
- Plus $\kappa(\mathbf{G})$ est grand, plus la matrice est mal conditionnée.

QCM : interprétation du nombre de conditionnement

Question

Que suggère un **grand** nombre de conditionnement pour $\mathbf{X}^\top\mathbf{X}$?

A. La matrice est bien conditionnée et l'estimation est très stable.
B. Les variables explicatives sont probablement fortement corrélées, et l'estimation peut être instable.
C. Le modèle contient forcément une erreur de calcul.
D. La variance des erreurs est nulle.

QCM : corrigé sur l'interprétation du conditionnement

Bonne réponse : B

Un grand nombre de conditionnement indique souvent que la matrice est proche d'être singulière.

- Cela est fréquemment lié à une forte multicolinéarité.
- Les estimations deviennent alors sensibles aux petites perturbations.
- L'interprétation des coefficients individuels devient plus délicate.

QCM : conséquences pratiques de la multicolinéarité

Question

Laquelle des affirmations suivantes décrit correctement une conséquence fréquente de la multicolinéarité ?

A. Les coefficients peuvent avoir des signes contre-intuitifs et de grandes erreurs standards.
B. Le modèle devient forcément non linéaire.
C. Les prédictions sont toujours mauvaises.
D. Les résidus deviennent indépendants.

QCM : corrigé sur les conséquences pratiques

Bonne réponse : A

La multicolinéarité peut rendre les coefficients difficiles à interpréter :

- erreurs standards élevées ;
- coefficients instables ;
- signes parfois contre-intuitifs ;
- tests individuels moins fiables.

Remarque importante

Un modèle multicolinéaire peut parfois encore bien prédire, mais les coefficients pris individuellement deviennent moins fiables pour l'interprétation.

Pourquoi la multicolinéarité complique l'interprétation ?

Idée générale

Lorsque les variables explicatives sont fortement corrélées entre elles, le modèle a du mal à distinguer clairement la contribution propre de chacune.

- **Erreurs standards élevées :**
  l'erreur standard mesure l'incertitude sur l'estimation d'un coefficient. Si deux variables apportent presque la même information, le modèle hésite sur la part attribuable à chacune, ce qui rend les estimations moins précises.
- **Coefficients instables :**
  de petits changements dans les données peuvent produire de grands changements dans les coefficients estimés. Par exemple, avec un échantillon légèrement différent, un coefficient peut passer de 2.1 à 0.7, ou même changer de signe.

Pourquoi la multicolinéarité complique l'interprétation ?

Idée générale

Lorsque les variables explicatives sont fortement corrélées entre elles, le modèle a du mal à distinguer clairement la contribution propre de chacune.

- **Signes parfois contre-intuitifs :**
  un coefficient peut devenir négatif alors qu'on s'attendait à un effet positif, ou l'inverse. Cela arrive parce que le modèle essaie de séparer l'effet de variables très corrélées, ce qui peut mener à une redistribution mathématiquement cohérente, mais peu intuitive, des effets.
- **Tests individuels moins fiables :**
  les tests sur les coefficients, par exemple $H_0 : \beta_j = 0$, deviennent moins informatifs. En effet, si l'erreur standard augmente, un coefficient qui semble important peut ne plus être statistiquement significatif.

Pourquoi la multicolinéarité complique l'interprétation ?

Idée générale

Lorsque les variables explicatives sont fortement corrélées entre elles, le modèle a du mal à distinguer clairement la contribution propre de chacune.

À retenir

La multicolinéarité ne veut pas forcément dire que le modèle prédit mal, mais elle rend l'interprétation individuelle des coefficients plus fragile.

QCM : solutions possibles

Question

Parmi les stratégies suivantes, lesquelles peuvent aider à réduire un problème de multicolinéarité ?

A. Retirer ou regrouper certaines variables explicatives redondantes.
B. Recueillir davantage de données si cela est possible.
C. Utiliser des méthodes de régularisation comme Ridge.
D. Toutes les réponses précédentes.

QCM : corrigé sur les solutions

Bonne réponse : D

Plusieurs stratégies peuvent être envisagées selon le contexte :

- retirer une variable redondante ;
- combiner des variables fortement corrélées ;
- collecter plus de données lorsque c'est possible ;
- utiliser une méthode de régularisation, comme Ridge.

Idée générale

On cherche à améliorer la stabilité de l'estimation et la robustesse de l'interprétation.

À retenir

- La multicolinéarité parfaite empêche l'inversibilité de $\mathbf{X}^\top\mathbf{X}$.
- Une forte multicolinéarité peut rendre l'estimation instable sans empêcher totalement le calcul.
- Le nombre de conditionnement mesure la sensibilité numérique du problème.
- Un grand nombre de conditionnement est souvent un signe d'instabilité.
- Des solutions existent : sélection de variables, regroupement, nouvelles données, régularisation.

Expression de l'intercept

QCM : expression de l'intercept

Considérons le modèle de régression linéaire multiple

$$Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip} + \varepsilon_i.$$

Supposons que les estimateurs MCO $\hat{\beta}_1, \ldots, \hat{\beta}_p$ soient connus.

Question

Laquelle des expressions suivantes donne correctement l'intercept estimé $\hat{\beta}_0$?

A. $\hat{\beta}_0 = \bar{y} + \sum_{j=1}^{p} \hat{\beta}_j \bar{x}_j$

B. $\hat{\beta}_0 = \bar{y} - \sum_{j=1}^{p} \hat{\beta}_j \bar{x}_j$

C. $\hat{\beta}_0 = \sum_{j=1}^{p} \hat{\beta}_j \bar{x}_j$

D. $\hat{\beta}_0 = \bar{y}$

QCM : corrigé de l'intercept

Bonne réponse : B

$$\hat{\beta}_0 = \bar{y} - \sum_{j=1}^{p} \hat{\beta}_j \bar{x}_j$$

Pourquoi ?

En prenant la moyenne du modèle ajusté

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \cdots + \hat{\beta}_p x_{ip},$$

on obtient

$$\bar{\hat{y}} = \hat{\beta}_0 + \sum_{j=1}^{p} \hat{\beta}_j \bar{x}_j.$$

Or, avec les MCO et un intercept dans le modèle,

$$\bar{\hat{y}} = \bar{y}.$$

QCM : interprétation de l'intercept

Sachant que

$$\hat{\beta}_0 = \bar{y} - \sum_{j=1}^{p} \hat{\beta}_j \bar{x}_j,$$

quelle interprétation est la plus juste ?

A. $\hat{\beta}_0$ est toujours égal à zéro.

B. $\hat{\beta}_0$ ajuste le modèle de sorte que l'hyperplan de régression passe par le point moyen des données.

C. $\hat{\beta}_0$ dépend uniquement de $\bar{y}$.

D. $\hat{\beta}_0$ n'a aucun rôle lorsque plusieurs prédicteurs sont présents.

QCM : corrigé d'interprétation de l'intercept

Bonne réponse : B

L'expression

$$\hat{\beta}_0 = \bar{y} - \sum_{j=1}^{p} \hat{\beta}_j \bar{x}_j$$

montre que l'intercept ajuste le modèle de sorte que le point moyen des données soit respecté.

Interprétation géométrique

L'hyperplan de régression passe par le point

$$(\bar{x}_1, \bar{x}_2, \ldots, \bar{x}_p, \bar{y}).$$

À retenir

- Lorsque le modèle contient un intercept, on a

$$\hat{\beta}_0 = \bar{y} - \sum_{j=1}^{p} \hat{\beta}_j \bar{x}_j.$$

- L'intercept ne dépend donc pas seulement de $\bar{y}$, mais aussi des moyennes des prédicteurs.
- Géométriquement, l'hyperplan ajusté passe par le point moyen des données.

Équivalence entre MCO et maximum de vraisemblance

QCM : hypothèse probabiliste

On considère le modèle

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

avec

$$\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I}).$$

Question

Quelle loi suit alors le vecteur $\mathbf{Y}$?

A. $\mathbf{Y} \sim \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I})$
B. $\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I})$
C. $\mathbf{Y} \sim \mathcal{N}(\boldsymbol{\beta}, \mathbf{X})$
D. $\mathbf{Y} \sim \mathcal{N}(\sigma^2\mathbf{I}, \mathbf{X}\boldsymbol{\beta})$

QCM : corrigé sur la loi de $\mathbf{Y}$

Bonne réponse : B

Si

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad \text{et} \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I}),$$

alors

$$\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I}).$$

QCM : corrigé sur la loi de $\mathbf{Y}$

Bonne réponse : B

Si

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad \text{et} \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I}),$$

alors

$$\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I}).$$

Justification

Comme $\mathbf{X}\boldsymbol{\beta}$ est un vecteur déterministe et $\boldsymbol{\varepsilon}$ est gaussien, $\mathbf{Y}$ est obtenu en translatant le vecteur gaussien $\boldsymbol{\varepsilon}$.

Ainsi,

$$\mathbb{E}[\mathbf{Y}] = \mathbb{E}[\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}] = \mathbf{X}\boldsymbol{\beta},$$

et

$$\mathrm{Var}(\mathbf{Y}) = \mathrm{Var}(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) = \mathrm{Var}(\boldsymbol{\varepsilon}) = \sigma^2\mathbf{I}.$$

Donc

$$\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I}).$$

QCM : fonction de vraisemblance

Sous cette hypothèse, quelle expression correspond à la vraisemblance de $\mathbf{y}$?

A.
$$L(\boldsymbol{\beta}, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})\right)$$

B.
$$L(\boldsymbol{\beta}, \sigma^2) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$$

C.
$$L(\boldsymbol{\beta}, \sigma^2) = \mathbf{X}^\top\mathbf{X}\boldsymbol{\beta}$$

D.
$$L(\boldsymbol{\beta}, \sigma^2) = \frac{1}{\sigma^2}(\mathbf{X}\boldsymbol{\beta} - \mathbf{y})$$

QCM : corrigé de la vraisemblance

Bonne réponse : A

Sous l'hypothèse gaussienne,

$$L(\boldsymbol{\beta}, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})\right).$$

Point clé

La vraisemblance dépend de $\boldsymbol{\beta}$ à travers le terme quadratique

$$(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}).$$

QCM : corrigé de la vraisemblance

Bonne réponse : A

Sous l'hypothèse gaussienne,

$$L(\boldsymbol{\beta}, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})\right).$$

Justification

Comme

$$\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I}),$$

les composantes $Y_1, \ldots, Y_n$ sont indépendantes et suivent des lois normales de moyenne $X_i\boldsymbol{\beta}$ et de variance σ^2.

La vraisemblance jointe est donc le produit des densités :

$$L(\boldsymbol{\beta}, \sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - X_i\boldsymbol{\beta})^2}{2\sigma^2}\right).$$

QCM : corrigé de la vraisemblance

En regroupant les termes, on obtient

$$L(\boldsymbol{\beta}, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^{n} (y_i - X_i\boldsymbol{\beta})^2 \right).$$

Or

$$\sum_{i=1}^{n} (y_i - X_i\boldsymbol{\beta})^2 = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}),$$

d'où la forme matricielle annoncée.

QCM : log-vraisemblance

Laquelle des expressions suivantes correspond à la log-vraisemblance (à constante près) ?

A.

$$\ell(\boldsymbol{\beta}, \sigma^2) = -\frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$$

B.

$$\ell(\boldsymbol{\beta}, \sigma^2) = \frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$$

C.

$$\ell(\boldsymbol{\beta}, \sigma^2) = \mathbf{X}^\top\mathbf{X}\boldsymbol{\beta}$$

D.

$$\ell(\boldsymbol{\beta}, \sigma^2) = \mathbf{y}^\top\mathbf{y}$$

QCM : corrigé de la log-vraisemblance

Bonne réponse : A

En prenant le logarithme, on obtient

$$\ell(\boldsymbol{\beta}, \sigma^2) = -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}).$$

À constante près

Pour σ^2 fixé, maximiser $\ell(\boldsymbol{\beta}, \sigma^2)$ revient à minimiser

$$(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}).$$

QCM : conséquence

Sous les hypothèses gaussiennes, quelle conclusion est correcte ?

A. L'estimateur du maximum de vraisemblance de $\boldsymbol{\beta}$ est différent de l'estimateur MCO.

B. L'estimateur du maximum de vraisemblance de $\boldsymbol{\beta}$ coïncide avec l'estimateur MCO.

C. Le maximum de vraisemblance ne s'applique pas à la régression multiple.

D. L'estimateur MV dépend seulement de σ^2.

QCM : corrigé de l'équivalence MCO–MV

Bonne réponse : B

Sous l'hypothèse

$$\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}),$$

maximiser la vraisemblance par rapport à $\boldsymbol{\beta}$ revient à minimiser

$$(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}).$$

Donc l'estimateur du maximum de vraisemblance de $\boldsymbol{\beta}$ est

$$\hat{\boldsymbol{\beta}}_{MV} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y},$$

c'est-à-dire exactement l'estimateur MCO.

Conclusion

Sous les hypothèses gaussiennes usuelles, les estimateurs **MCO** et **MV** coïncident pour $\boldsymbol{\beta}$.

À retenir

- Si
$$\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}),$$
alors
$$\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}).$$
- La log-vraisemblance dépend de $\boldsymbol{\beta}$ à travers
$$(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}).$$
- Maximiser la vraisemblance revient donc à minimiser la somme des carrés des résidus.
- Sous les hypothèses gaussiennes, l'estimateur MV de $\boldsymbol{\beta}$ coïncide avec l'estimateur MCO.

Solution : Équivalence avec le Maximum de Vraisemblance

- **Interprétation Géométrique**
  - **Projection orthogonale sur le sous-espace engendré par les prédicteurs:**
  - L'hyperplan en bleu représente la **régression linéaire multiple**, c'est-à-dire le sous-espace sur lequel les valeurs prédites $\hat{y}$ sont projetées ($\hat{\boldsymbol{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$).
  - Les **lignes verticales vertes pointillées** représentent les **résidus**, c'est-à-dire la différence entre les points de données réels (rouges) et leurs projections sur l'hyperplan (prédictions).
  - La **minimisation des moindres carrés** ajuste cet hyperplan de manière à minimiser la somme des carrés des longueurs de ces segments.

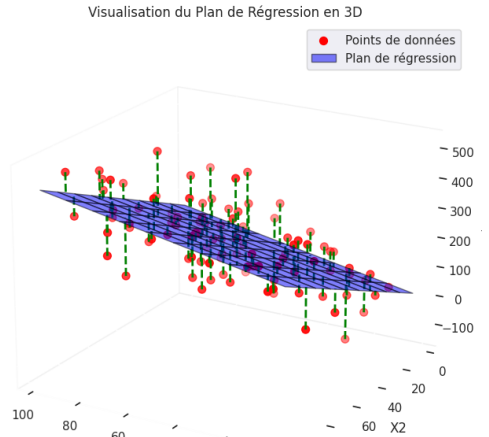

Table des Matières

1. Régression Linéaire Multiple
2. Décomposition de la Variabilité Totale
3. ANOVA en Régression Linéaire Multiple
4. Exercice : Boston Housing Prices Dataset
5. Intervalle de Confiance et Intervalle de Prédiction
6. Annexe

Décomposition de la Variabilité Totale

QCM : variabilité totale

En régression multiple, on cherche à expliquer la variabilité de Y à l'aide de plusieurs variables explicatives.

Question

Laquelle des expressions suivantes représente correctement la variabilité totale des observations autour de leur moyenne $\bar{y}$?

A. $SC_{totale} = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2$
B. $SC_{totale} = \sum_{i=1}^{n}(y_i - \bar{y})^2$
C. $SC_{totale} = \sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2$
D. $SC_{totale} = \sum_{i=1}^{n}(y_i - \hat{\beta}_0)^2$

QCM : corrigé sur la variabilité totale

Bonne réponse : B

La variabilité totale des observations autour de leur moyenne est donnée par

$$SC_{totale} = \sum_{i=1}^{n} (y_i - \bar{y})^2.$$

Interprétation

Cette quantité mesure à quel point les observations y_i sont dispersées autour de la moyenne $\bar{y}$.

QCM : décomposition d'une observation

En régression multiple, chaque observation peut s'écrire comme

$$y_i = \hat{y}_i + e_i,$$

où $e_i = y_i - \hat{y}_i$.

Question

Laquelle des expressions suivantes décompose correctement l'écart entre y_i et $\bar{y}$?

A. $y_i - \bar{y} = (\hat{y}_i - \bar{y}) + e_i$
B. $y_i - \bar{y} = (y_i - \hat{y}_i) + (\bar{y} - \hat{y}_i)$
C. $y_i - \bar{y} = e_i - \hat{y}_i$
D. $y_i - \bar{y} = \hat{y}_i + e_i + \bar{y}$

QCM : corrigé sur la décomposition d'une observation

Bonne réponse : A

Comme

$$y_i = \hat{y}_i + e_i,$$

on obtient en soustrayant $\bar{y}$ des deux côtés :

$$y_i - \bar{y} = (\hat{y}_i - \bar{y}) + e_i.$$

Interprétation

- $\hat{y}_i - \bar{y}$ représente la partie expliquée par le modèle ;
- $e_i = y_i - \hat{y}_i$ représente la partie résiduelle, donc non expliquée.

QCM : relation fondamentale

À partir de

$$y_i - \bar{y} = (\hat{y}_i - \bar{y}) + e_i,$$

on cherche à obtenir une décomposition des sommes de carrés.

Question

Quelle relation fondamentale obtient-on en régression multiple ?

A.

$$SC_{totale} = SC_{reg} \times SC_{res}$$

B.

$$SC_{totale} = SC_{reg} + SC_{res}$$

C.

$$SC_{res} = SC_{totale} + SC_{reg}$$

D.

$$SC_{reg} = SC_{totale} + SC_{res}$$

QCM : corrigé de la relation fondamentale

Bonne réponse : B

En régression multiple, on a la relation fondamentale

$$SC_{totale} = SC_{reg} + SC_{res}.$$

Avec

$$SC_{totale} = \sum_{i=1}^{n}(y_i - \bar{y})^2, \qquad SC_{reg} = \sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2, \qquad SC_{res} = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2.$$

QCM : interprétation des trois quantités

Quelle association est correcte ?

A. SC_{totale} : variabilité résiduelle ; SC_{reg} : variabilité totale ; SC_{res} : variabilité expliquée.

B. SC_{totale} : variabilité totale ; SC_{reg} : variabilité expliquée ; SC_{res} : variabilité résiduelle.

C. SC_{totale} : moyenne des résidus ; SC_{reg} : variance des erreurs ; SC_{res} : moyenne de Y.

D. SC_{totale} : intercept ; SC_{reg} : pente ; SC_{res} : covariance.

QCM : corrigé d'interprétation

Bonne réponse : B

- SC_{totale} mesure la variabilité totale des observations autour de $\bar{y}$.
- SC_{reg} mesure la variabilité expliquée par le modèle.
- SC_{res} mesure la variabilité résiduelle, donc non expliquée.

QCM : écriture matricielle

Laquelle des écritures matricielles suivantes est correcte ?

A. $SC_{totale} = \|\mathbf{y} - \bar{y}\mathbf{1}\|_2^2, \quad SC_{reg} = \|\mathbf{X}\hat{\boldsymbol{\beta}} - \bar{y}\mathbf{1}\|_2^2, \quad SC_{res} = \|\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|_2^2$

B. $SC_{totale} = \|\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|_2^2, \quad SC_{reg} = \|\mathbf{y} - \bar{y}\mathbf{1}\|_2^2, \quad SC_{res} = \|\mathbf{X}\hat{\boldsymbol{\beta}} - \bar{y}\mathbf{1}\|_2^2$

C. $SC_{totale} = \|\mathbf{y}\|_2^2, \quad SC_{reg} = \|\hat{\boldsymbol{\beta}}\|_2^2, \quad SC_{res} = \|\mathbf{X}\|_2^2$

D. $SC_{totale} = \|\bar{y}\mathbf{1}\|_2^2, \quad SC_{reg} = \|\mathbf{y}\|_2^2, \quad SC_{res} = \|\hat{\boldsymbol{\beta}}\|_2^2$

QCM : corrigé en écriture matricielle

Bonne réponse : A

En écriture matricielle,

$$SC_{totale} = \|\mathbf{y} - \bar{y}\mathbf{1}\|_2^2,$$

$$SC_{reg} = \|\mathbf{X}\hat{\boldsymbol{\beta}} - \bar{y}\mathbf{1}\|_2^2,$$

$$SC_{res} = \|\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|_2^2.$$

Lecture géométrique

- SC_{reg} correspond à la partie expliquée par la projection sur le sous-espace engendré par $\mathbf{X}$.
- SC_{res} correspond à la norme au carré du vecteur des résidus.

QCM : coefficient de détermination R^2

Question

Laquelle des expressions suivantes définit correctement le coefficient de détermination R^2 ?

A.

$$R^2 = \frac{SC_{res}}{SC_{totale}}$$

B.

$$R^2 = \frac{SC_{reg}}{SC_{totale}} = 1 - \frac{SC_{res}}{SC_{totale}}$$

C.

$$R^2 = \frac{SC_{totale}}{SC_{reg}}$$

D.

$$R^2 = SC_{reg} - SC_{res}$$

QCM : corrigé sur R^2

Bonne réponse : B

Le coefficient de détermination est défini par

$$R^2 = \frac{SC_{reg}}{SC_{totale}} = 1 - \frac{SC_{res}}{SC_{totale}}.$$

- Si $R^2 \approx 1$, le modèle explique une grande partie de la variabilité.
- Si $R^2 \approx 0$, le modèle n'explique guère mieux les données qu'une simple moyenne.

QCM : limite de R^2 en régression multiple

Question

Pourquoi faut-il être prudent avec R^2 en régression multiple ?

A. Parce que R^2 diminue toujours lorsqu'on ajoute des variables explicatives.

B. Parce que R^2 peut augmenter lorsqu'on ajoute des prédicteurs, même peu informatifs.

C. Parce que R^2 est toujours négatif.

D. Parce que R^2 ne dépend jamais du modèle.

QCM : corrigé sur la limite de R^2

Bonne réponse : B

En régression multiple, ajouter des variables explicatives tend à augmenter R^2, même si ces variables apportent peu d'information réelle.

Conséquence

Pour pénaliser l'ajout inutile de variables, on utilise souvent le coefficient de détermination ajusté.

QCM : R^2 ajusté

Question

Quelle est la formule correcte du coefficient de détermination ajusté ?

A.

$$R^2_{\text{ajusté}} = 1 - \frac{(1 - R^2)(n - 1)}{n - p - 1}$$

B.

$$R^2_{\text{ajusté}} = 1 - \frac{(1 - R^2)(n - p - 1)}{n - 1}$$

C.

$$R^2_{\text{ajusté}} = \frac{R^2}{n - p - 1}$$

D.

$$R^2_{\text{ajusté}} = R^2 + (n - p - 1)$$

QCM : corrigé sur R^2 ajusté

Bonne réponse : A

Le coefficient de détermination ajusté est donné par

$$R^2_{\text{ajusté}} = 1 - \frac{(1 - R^2)(n-1)}{n-p-1}.$$

Interprétation

Contrairement à R^2, cette mesure tient compte du nombre de prédicteurs p et pénalise l'ajout de variables peu utiles.

À retenir

- La variabilité totale se décompose en une partie expliquée et une partie résiduelle :

$$SC_{totale} = SC_{reg} + SC_{res}.$$

- Le coefficient R^2 mesure la proportion de variabilité expliquée.
- En régression multiple, R^2 peut augmenter artificiellement lorsqu'on ajoute des variables.
- Le R^2 ajusté corrige partiellement ce phénomène.

Table des Matières

1. Régression Linéaire Multiple
2. Décomposition de la Variabilité Totale
3. ANOVA en Régression Linéaire Multiple
4. Exercice : Boston Housing Prices Dataset
5. Intervalle de Confiance et Intervalle de Prédiction
6. Annexe

ANOVA en Régression Linéaire Multiple

Pourquoi faire une ANOVA en régression multiple ?

- En régression multiple, on cherche à expliquer la variabilité de Y à l'aide de plusieurs variables explicatives $X_1, \ldots, X_p$.
- L'ANOVA permet d'évaluer si la partie expliquée par le modèle est suffisamment grande par rapport à la partie résiduelle.
- L'idée est donc de comparer :

$$SC_{\text{reg}} \quad \text{et} \quad SC_{\text{res}}.$$

Idée clé

Si la variabilité expliquée par le modèle est nettement plus grande que la variabilité résiduelle, alors le modèle semble apporter une information utile.

Rappel

$$SC_{\text{totale}} = SC_{\text{reg}} + SC_{\text{res}}.$$

QCM : que teste l'ANOVA en régression multiple ?

Question

En régression multiple, l'ANOVA sert principalement à vérifier si :

A. les résidus sont tous égaux à zéro ;
B. la moyenne de Y est égale à zéro ;
C. la variabilité expliquée par le modèle est significativement plus grande que la variabilité résiduelle ;
D. tous les coefficients estimés sont positifs.

QCM : corrigé sur l'objectif de l'ANOVA

Bonne réponse : C

L'ANOVA en régression multiple sert à évaluer si la variabilité expliquée par le modèle

$$SC_{\text{reg}}$$

est significativement plus grande que la variabilité résiduelle

$$SC_{\text{res}}.$$

Interprétation

On cherche à savoir si le modèle fait mieux qu'un modèle trivial qui ne prédirait que la moyenne.

Rappel utile : pourquoi la loi du χ^2 apparaît-elle ?

- Si $Z_1, \ldots, Z_k$ sont indépendantes et suivent une loi $\mathcal{N}(0,1)$, alors

$$\sum_{i=1}^{k} Z_i^2 \sim \chi_k^2.$$

- En régression, les résidus et certaines quantités quadratiques normalisées conduisent naturellement à des sommes de carrés.
- C'est pourquoi des quantités comme

$$\frac{SC_{\text{res}}}{\sigma^2}$$

ou

$$\frac{SC_{\text{reg}}}{\sigma^2}$$

apparaissent dans des résultats liés à des lois du χ^2, sous les hypothèses du modèle.

QCM : degrés de liberté résiduels

Dans le modèle

$$Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip} + \varepsilon_i,$$

on estime $p+1$ paramètres.

Question

Pourquoi le terme résiduel a-t-il $n-p-1$ degrés de liberté ?

A. Parce qu'on a retiré $p+1$ degrés de liberté pour estimer $\beta_0, \beta_1, \ldots, \beta_p$.
B. Parce qu'il y a exactement p résidus.
C. Parce que $SC_{\text{res}} = SC_{\text{totale}}$.
D. Parce que la moyenne de Y vaut zéro.

QCM : corrigé sur les degrés de liberté résiduels

Bonne réponse : A

Le modèle estime $p+1$ paramètres :

$$\beta_0, \beta_1, \ldots, \beta_p.$$

Donc, sur les n degrés de liberté initiaux, il en reste

$$n-(p+1) = n-p-1$$

pour la partie résiduelle.

Résultat important

Sous les hypothèses du modèle,

$$\frac{SC_{\text{res}}}{\sigma^2} \sim \chi^2_{n-p-1}.$$

Du χ^2 à la loi de Fisher

- Si
$$U \sim \chi^2_{d_1} \quad \text{et} \quad V \sim \chi^2_{d_2},$$
avec U et V indépendantes, alors
$$F = \frac{U/d_1}{V/d_2} \sim F_{d_1,d_2}.$$
- En ANOVA, cette idée permet de comparer deux quantités quadratiques ramenées à leurs degrés de liberté.
- Ici, on comparera une variabilité expliquée moyenne à une variabilité résiduelle moyenne.

QCM : hypothèse nulle du test global

Question

Quelle est l'hypothèse nulle du test F global en régression multiple ?

A.

$$H_0 : \beta_0 = 0$$

B.

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0$$

C.

$$H_0 : SC_{\text{totale}} = 0$$

D.

$$H_0 : R^2 = 1$$

QCM : corrigé sur l'hypothèse nulle

Bonne réponse : B

Le test F global en régression multiple teste

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0.$$

Sens de cette hypothèse

Sous H_0, aucune des variables explicatives $X_1, \ldots, X_p$ n'apporte d'information utile pour prédire Y, au-delà d'un modèle constant.

Hypothèse alternative

$$H_1 : \text{au moins un } \beta_j \neq 0.$$

QCM : statistique de test F

Question

Laquelle des expressions suivantes correspond à la statistique de test globale en ANOVA pour la régression multiple ?

A.

$$F_{\text{stat}} = \frac{SC_{\text{res}}}{SC_{\text{reg}}}$$

B.

$$F_{\text{stat}} = \frac{SC_{\text{totale}}}{n}$$

C.

$$F_{\text{stat}} = \frac{SC_{\text{reg}}/p}{SC_{\text{res}}/(n-p-1)} = \frac{MC_{\text{reg}}}{MC_{\text{res}}}$$

D.

$$F_{\text{stat}} = \frac{R^2}{1-R^2}$$

QCM : corrigé sur la statistique F

Bonne réponse : C

La statistique de test est

$$F_{\text{stat}} = \frac{SC_{\text{reg}}/p}{SC_{\text{res}}/(n-p-1)} = \frac{MC_{\text{reg}}}{MC_{\text{res}}}.$$

- $MC_{\text{reg}} = \dfrac{SC_{\text{reg}}}{p}$ est la moyenne carrée expliquée ;
- $MC_{\text{res}} = \dfrac{SC_{\text{res}}}{n-p-1}$ est la moyenne carrée résiduelle.

Sous H_0

$$F_{\text{stat}} \sim F_{p,n-p-1}.$$

Pourquoi un grand F est-il convaincant ?

- Si H_0 est vraie, la variabilité expliquée et la variabilité résiduelle devraient être du même ordre de grandeur.
- Dans ce cas, le ratio
$$\frac{MC_{\text{reg}}}{MC_{\text{res}}}$$
a tendance à être proche de 1.
- Si $MC_{\text{reg}} \gg MC_{\text{res}}$, alors
$$F_{\text{stat}} \gg 1,$$
ce qui suggère que le modèle explique une part importante de la variabilité de Y.

Intuition

Plus F est grand, plus il devient difficile de croire que la variabilité expliquée observée soit due au simple hasard.

Cas intuitif : régression nulle

- Si $X_1, \ldots, X_p$ n'ont pratiquement aucun effet sur Y, alors l'hyperplan de régression est presque horizontal.
- La variabilité expliquée est faible :

$$SC_{\text{reg}} \approx 0.$$

- La variabilité résiduelle est alors proche de la variabilité totale :

$$SC_{\text{res}} \approx SC_{\text{totale}}.$$

- On s'attend donc à ce que

$$F_{\text{stat}} \approx 1.$$

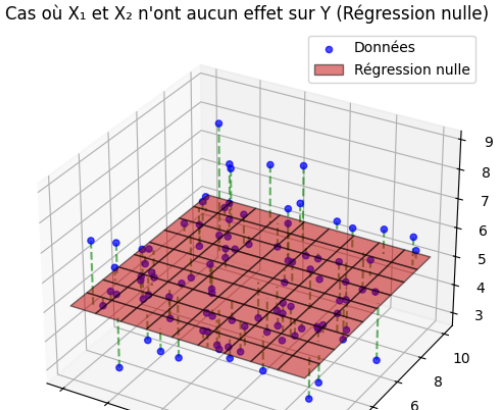

Cas intuitif : bonne régression

- Si les variables explicatives ont un effet important sur Y, alors l'hyperplan ajusté suit la tendance des données.
- La variabilité expliquée devient grande :

$$SC_{\text{reg}} \gg 0.$$

- La variabilité résiduelle devient relativement faible :

$$SC_{\text{res}} \ll SC_{\text{totale}}.$$

- On s'attend alors à ce que

$$F_{\text{stat}} \gg 1.$$

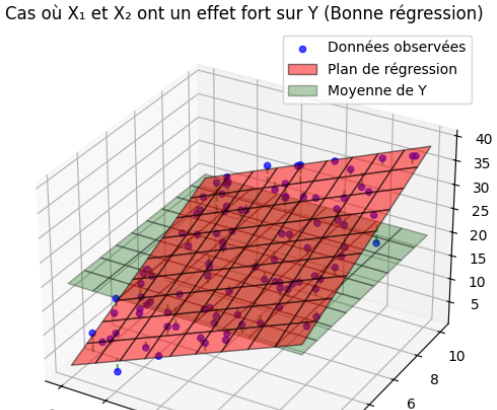

QCM : décision du test

Question

Quand rejette-t-on H_0 dans le test global F ?

A. Lorsque F_{stat} est très petit.

B. Lorsque F_{stat} est suffisamment grand, ou de manière équivalente lorsque la p-valeur est inférieure à α.

C. Toujours dès que $R^2 > 0$.

D. Dès que $n > p$.

QCM : corrigé sur la décision

Bonne réponse : B

On rejette H_0 lorsque

$$F_{\text{stat}}$$

est suffisamment grand par rapport à la loi de Fisher $F_{p,n-p-1}$, ou de manière équivalente lorsque la p-valeur est inférieure au niveau α.

Conclusion statistique

Si on rejette H_0, on conclut qu'au moins une variable explicative contribue significativement à la prédiction de Y.

Tableau de l'ANOVA pour la régression multiple

Tableau de l'ANOVA en régression multiple

Source	Somme des carrés	dl	Moyenne carrée	Statistique F
Régression	SC_{reg}	p	$MC_{\text{reg}} = \frac{SC_{\text{reg}}}{p}$	$F = \frac{MC_{\text{reg}}}{MC_{\text{res}}}$
Résiduel	SC_{res}	$n-p-1$	$MC_{\text{res}} = \frac{SC_{\text{res}}}{n-p-1}$	
Total	SC_{totale}	$n-1$		

- Le test global compare la variabilité expliquée moyenne à la variabilité résiduelle moyenne.
- Si F est grand, le modèle semble expliquer significativement une partie de la variabilité de Y.

Résumé : ANOVA en régression multiple

- L'ANOVA s'appuie sur la décomposition

$$SC_{\text{totale}} = SC_{\text{reg}} + SC_{\text{res}}.$$

- Elle teste si la variabilité expliquée par le modèle est significativement plus grande que la variabilité résiduelle.
- Le test global repose sur

$$H_0 : \beta_1 = \cdots = \beta_p = 0 \quad \text{contre} \quad H_1 : \text{au moins un } \beta_j \neq 0.$$

- La statistique utilisée est

$$F_{\text{stat}} = \frac{MC_{\text{reg}}}{MC_{\text{res}}} \sim F_{p,n-p-1} \quad \text{sous } H_0.$$

- Si F_{stat} est grand, on rejette H_0.

Table des Matières

1. Régression Linéaire Multiple
2. Décomposition de la Variabilité Totale
3. ANOVA en Régression Linéaire Multiple
4. Exercice : Boston Housing Prices Dataset
5. Intervalle de Confiance et Intervalle de Prédiction
6. Annexe

Boston Housing Prices Dataset

Objectif de l'exercice

- Charger et explorer un jeu de données réel.
- Construire un modèle de régression linéaire multiple de trois manières :
  1. avec la formule analytique des MCO ;
  2. avec `LinearRegression` de `sklearn` ;
  3. avec `OLS` de `statsmodels`.
- Comparer les résultats en termes de :
  - coefficients $\hat{\boldsymbol{\beta}}$;
  - coefficient R^2 ;
  - tableau ANOVA.

Introduction à la librairie ISLP

Pourquoi utiliser ISLP ?

- ISLP est une librairie Python associée au manuel *Introduction to Statistical Learning*.
- Elle permet de charger facilement plusieurs jeux de données classiques, dont Boston.
- Nous allons l'utiliser pour récupérer rapidement un jeu de données réel.

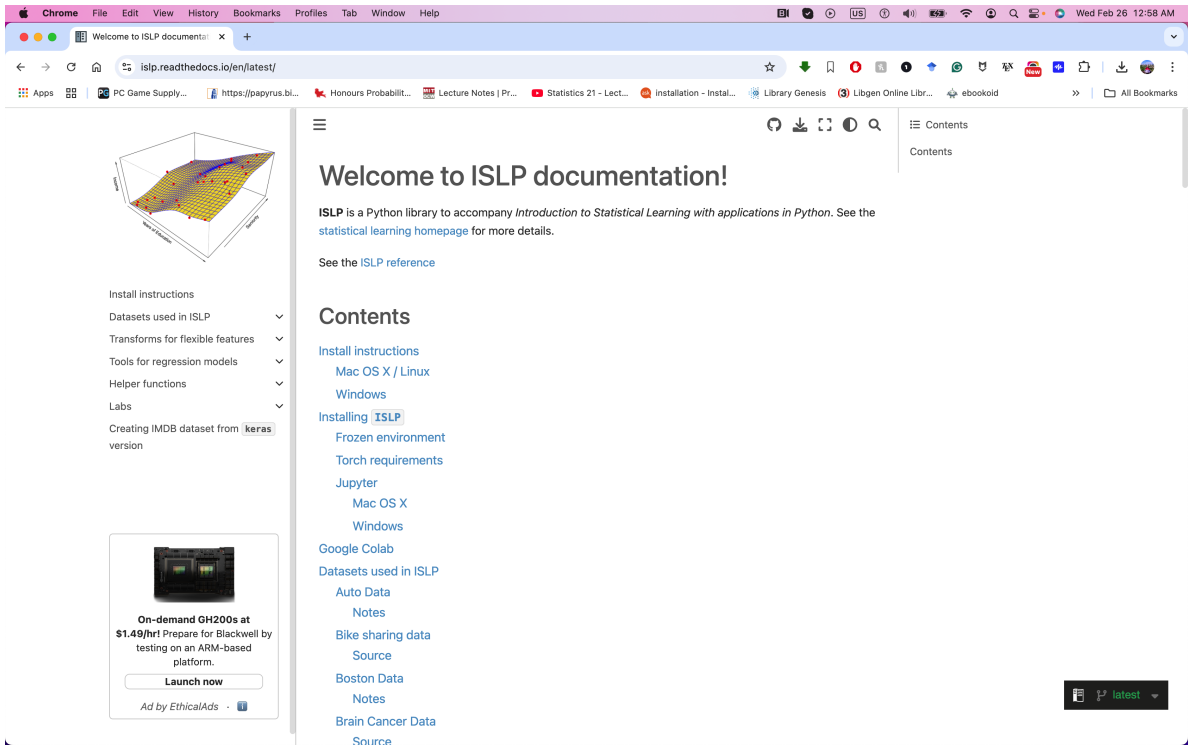

Code à compléter : installation

Question

Quelle commande faut-il exécuter dans Colab pour installer la librairie `ISLP` ?

```
# Compléter la commande d'installation
----------------------------
```

Correction

```
!pip install ISLP
```

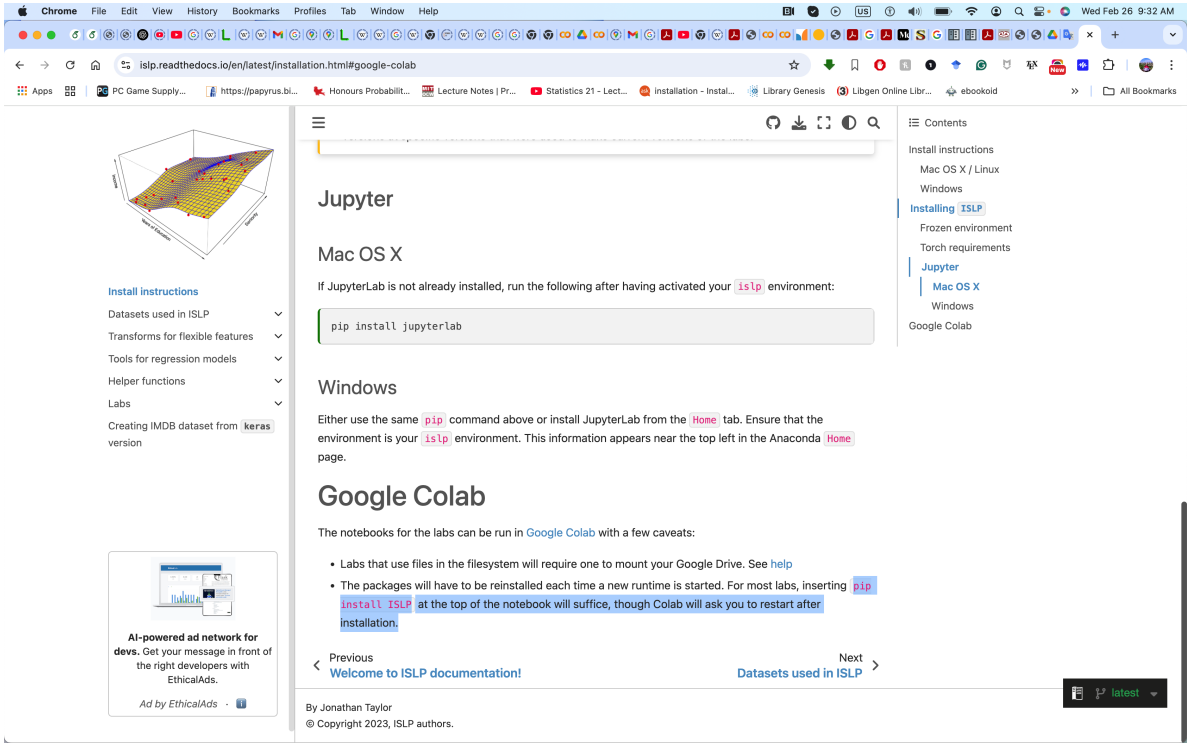

Partie 1 : Chargement et Exploration des Données

Tâches à réaliser

- Charger le jeu de données **Boston Housing**.
- Afficher les premières lignes.
- Identifier :
  - les variables explicatives ;
  - la variable cible.
- Vérifier la taille du jeu de données, les types et la présence éventuelle de valeurs manquantes.

Code à compléter : chargement du dataset

```
from ISLP import load_data

# Charger le dataset Boston Housing
Boston = ______________________

print("Premières lignes :")
print(Boston.________())

print("Colonnes :")
print(Boston.__________)

print("Dimensions :")
print(Boston.________)

print("Valeurs manquantes :")
print(Boston.__________________)
```

Correction : chargement et exploration

```
from ISLP import load_data

Boston = load_data('Boston')

print("Premières lignes :")
print(Boston.head())

print("Colonnes :")
print(Boston.columns)

print("Dimensions :")
print(Boston.shape)

print("Valeurs manquantes :")
print(Boston.isnull().sum())
```

Sortie affichée : premières lignes

```
Premières lignes :
      crim    zn  indus  chas    nox     rm   age     dis  rad  tax  ptratio  lstat  medv
0  0.00632  18.0   2.31     0  0.538  6.575  65.2  4.0900    1  296     15.3   4.98  24.0
1  0.02731   0.0   7.07     0  0.469  6.421  78.9  4.9671    2  242     17.8   9.14  21.6
2  0.02729   0.0   7.07     0  0.469  7.185  61.1  4.9671    2  242     17.8   4.03  34.7
3  0.03237   0.0   2.18     0  0.458  6.998  45.8  6.0622    3  222     18.7   2.94  33.4
4  0.06905   0.0   2.18     0  0.458  7.147  54.2  6.0622    3  222     18.7   5.33  36.2
```

Sortie affichée : colonnes, dimensions, valeurs manquantes

```
Colonnes :
Index(['crim', 'zn', 'indus', 'chas', 'nox', 'rm', 'age', 'dis',
       'rad', 'tax', 'ptratio', 'lstat', 'medv'],
      dtype='object')

Dimensions :
(506, 13)

Valeurs manquantes :
crim       0
zn         0
indus      0
chas       0
nox        0
rm         0
age        0
dis        0
rad        0
tax        0
ptratio    0
lstat      0
medv       0
dtype: int64
```

Question de compréhension

QCM

Dans le dataset Boston Housing, quelle est la variable cible du problème de régression ?

A. `rm`
B. `crim`
C. `medv`
D. `lstat`

Corrigé

Bonne réponse : C

La variable cible est `medv`, c'est-à-dire la valeur médiane des logements (en milliers de dollars).

Colonnes du dataset Boston Housing

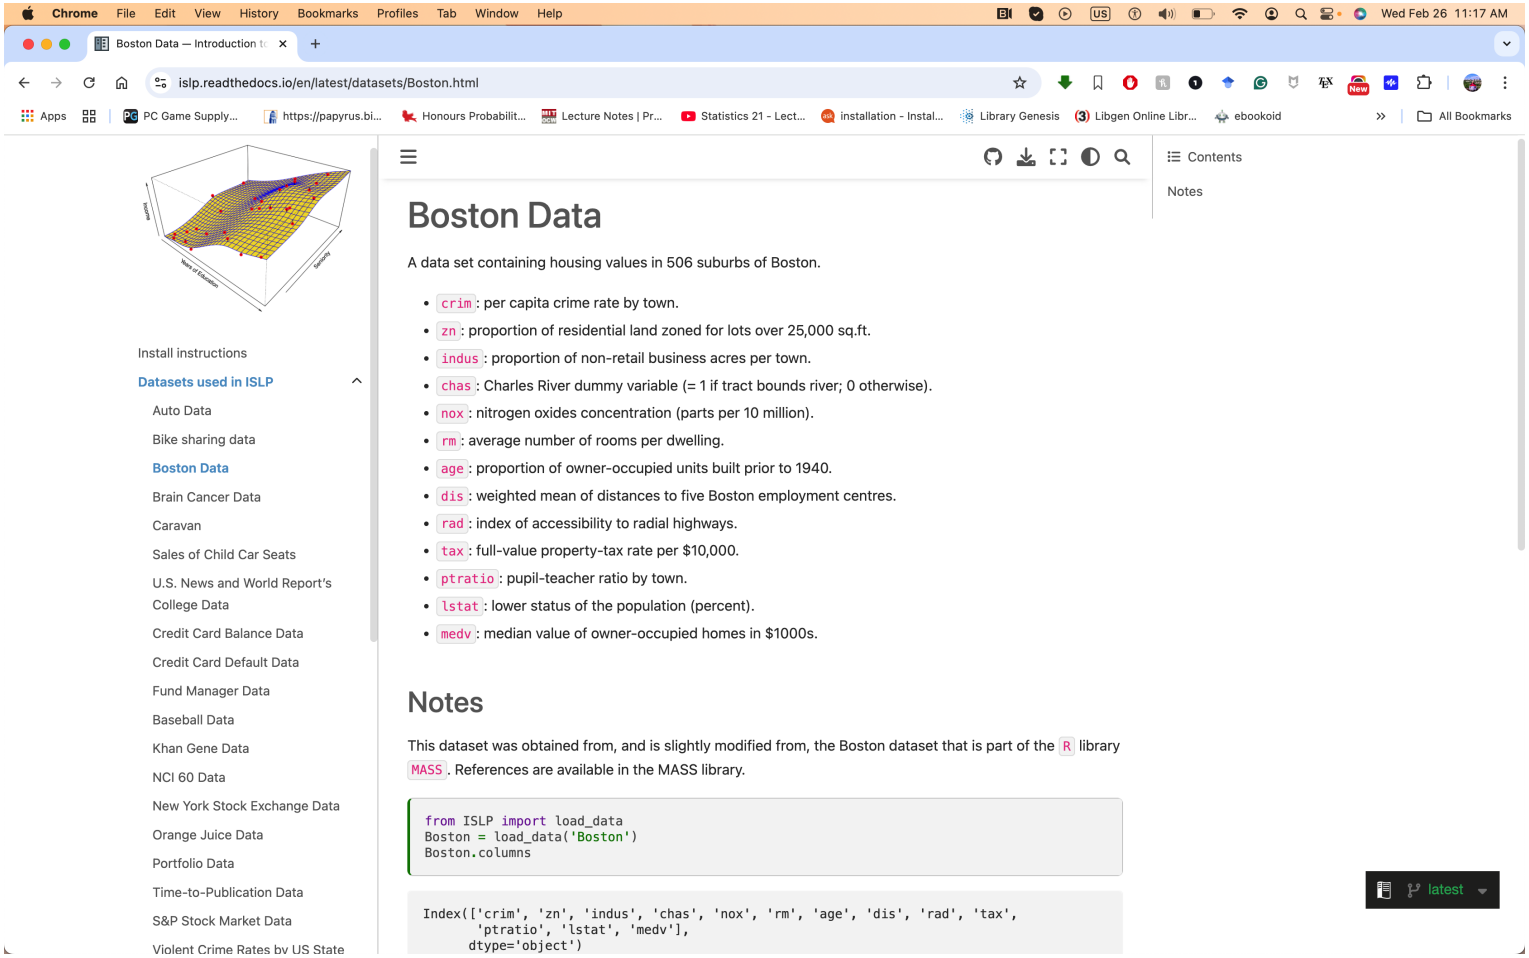

Install instructions

Datasets used in ISLP

- Auto Data
- Bike sharing data
- Boston Data
- Brain Cancer Data
- Caravan
- Sales of Child Car Seats
- U.S. News and World Report's College Data
- Credit Card Balance Data
- Credit Card Default Data
- Fund Manager Data
- Baseball Data
- Khan Gene Data
- NCI 60 Data
- New York Stock Exchange Data
- Orange Juice Data
- Portfolio Data
- Time-to-Publication Data
- S&P Stock Market Data
- Violent Crime Rates by US State

Boston Data

A data set containing housing values in 506 suburbs of Boston.

- `crim` : per capita crime rate by town.
- `zn` : proportion of residential land zoned for lots over 25,000 sq.ft.
- `indus` : proportion of non-retail business acres per town.
- `chas` : Charles River dummy variable (= 1 if tract bounds river; 0 otherwise).
- `nox` : nitrogen oxides concentration (parts per 10 million).
- `rm` : average number of rooms per dwelling.
- `age` : proportion of owner-occupied units built prior to 1940.
- `dis` : weighted mean of distances to five Boston employment centres.
- `rad` : index of accessibility to radial highways.
- `tax` : full-value property-tax rate per $10,000.
- `ptratio` : pupil-teacher ratio by town.
- `lstat` : lower status of the population (percent).
- `medv` : median value of owner-occupied homes in $1000s.

Notes

This dataset was obtained from, and is slightly modified from, the Boston dataset that is part of the `R` library `MASS`. References are available in the MASS library.

```
from ISLP import load_data
Boston = load_data('Boston')
Boston.columns
```

```
Index(['crim', 'zn', 'indus', 'chas', 'nox', 'rm', 'age', 'dis', 'rad', 'tax',
       'ptratio', 'lstat', 'medv'],
      dtype='object')
```

Lecture des variables

- **crim** : taux de criminalité par zone ;
- **zn** : proportion de terrains résidentiels ;
- **indus** : proportion de terrains non résidentiels ;
- **chas** : proximité de la rivière Charles ;
- **nox** : pollution de l'air ;
- **rm** : nombre moyen de pièces ;
- **age** : proportion de logements anciens ;
- **dis** : distance aux centres d'emploi ;
- **rad** : accessibilité aux autoroutes ;
- **tax** : taux d'imposition ;
- **ptratio** : ratio élèves/enseignants ;
- **lstat** : proportion de population à faible statut socio-économique ;
- **medv** : valeur médiane des logements.

Code à compléter : séparation X et Y

```
# Séparer les variables explicatives et la cible
X = Boston.________________________
Y = Boston['______'].values

print("Dimensions de X :", X.shape)
print("Dimensions de Y :", Y.shape)
```

Correction : séparation X et Y

```
X = Boston.drop(columns=['medv'])
Y = Boston['medv'].values

print("Dimensions de X :", X.shape)
print("Dimensions de Y :", Y.shape)
```

Sortie affichée : dimensions de X et Y

```
Dimensions de X : (506, 12)
Dimensions de Y : (506,)
```

Partie 2 : Régression Multiple avec 3 Méthodes

Objectif statistique

- On veut prédire `medv` à partir des autres variables.
- Le modèle est

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon.$$

- Nous allons comparer trois façons d'ajuster ce modèle.

Question

QCM

Avant d'utiliser la formule analytique des MCO, que faut-il ajouter à la matrice $\mathbf{X}$?

A. Une colonne de zéros
B. Une colonne de moyennes
C. Une colonne de 1 pour l'intercept
D. Une colonne contenant Y

Corrigé

Bonne réponse : C

Pour utiliser la formule analytique des MCO avec intercept, on ajoute une colonne de 1 à la matrice des prédicteurs.

Code à compléter : formule analytique des MCO

```
import numpy as np

# Ajouter une colonne de 1 pour l'intercept
X_with_intercept = np.c_[________________, X]

# Estimation analytique des coefficients
beta_mco = np.linalg.inv(_____________________________) @ ____________________ @ Y

# Prédictions
Y_pred_mco = ______________________________
```

Correction : formule analytique des MCO

```
import numpy as np

X_with_intercept = np.c_[np.ones(X.shape[0]), X]

beta_mco = np.linalg.inv(X_with_intercept.T @ X_with_intercept) @ X_with_intercept.T @ Y

Y_pred_mco = X_with_intercept @ beta_mco
```

Code à compléter : LinearRegression

```
from sklearn.linear_model import LinearRegression

model_sklearn = ______________________
model_sklearn._____(X, Y)

Y_pred_sklearn = model_sklearn._______(X)
```

Correction : LinearRegression

```
from sklearn.linear_model import LinearRegression

model_sklearn = LinearRegression()
model_sklearn.fit(X, Y)

Y_pred_sklearn = model_sklearn.predict(X)
```

Code à compléter : OLS de statsmodels

```
import statsmodels.formula.api as smf

formula = "medv ~ " + " + ".join(_______________)

model_sm = smf.ols(________________, data=Boston).____()

Y_pred_sm = model_sm.____________
```

Correction : OLS de statsmodels

```
import statsmodels.formula.api as smf

formula = "medv ~ " + " + ".join(X.columns)

model_sm = smf.ols(formula, data=Boston).fit()

Y_pred_sm = model_sm.fittedvalues
```

Partie 3 : Calcul du Tableau ANOVA

Objectif

- Calculer :

$$SC_{totale},\ SC_{reg},\ SC_{res}$$

- En déduire :

$$MC_{reg},\ MC_{res},\ F_{stat},\ p\text{-valeur}$$

- Construire un tableau ANOVA global pour le modèle.

Code à compléter : fonction ANOVA

```
from scipy.stats import f
import pandas as pd
def compute_anova(Y, Y_pred, n, p):
    Y_mean = np.mean(Y)
    # Sommes des carrés
    SC_tot = np.sum((____________________) ** 2)
    SC_reg = np.sum((____________________) ** 2)
    SC_res = np.sum((____________________) ** 2)
    # Degrés de liberté
    df_reg = ______
    df_res = ___________________
    # Moyennes des carrés
    MC_reg = ___________________
    MC_res = ___________________
    # Statistique F et p-valeur
    F_stat = ___________________
    p_value = ___________________
    anova_table = pd.DataFrame({
        "Source": ["Régression", "Résiduel", "Total"],
        "Somme des Carrés (SC)": [SC_reg, SC_res, SC_tot],
        "Degrés de Liberté (dl)": [df_reg, df_res, n - 1],
        "Moyenne des Carrés (MC)": [MC_reg, MC_res, ""],
        "F_stat": [F_stat, "", ""],
        "p-value": [p_value, "", ""]
    })
    return anova_table
```

Correction : fonction ANOVA

```
from scipy.stats import f
import pandas as pd

def compute_anova(Y, Y_pred, n, p):
    Y_mean = np.mean(Y)

    SC_tot = np.sum((Y - Y_mean) ** 2)
    SC_reg = np.sum((Y_pred - Y_mean) ** 2)
    SC_res = np.sum((Y - Y_pred) ** 2)

    df_reg = p
    df_res = n - p - 1

    MC_reg = SC_reg / df_reg
    MC_res = SC_res / df_res

    F_stat = MC_reg / MC_res
    p_value = 1 - f.cdf(F_stat, df_reg, df_res)

    anova_table = pd.DataFrame({
        "Source": ["Régression", "Résiduel", "Total"],
        "Somme des Carrés (SC)": [SC_reg, SC_res, SC_tot],
        "Degrés de Liberté (dl)": [df_reg, df_res, n - 1],
        "Moyenne des Carrés (MC)": [MC_reg, MC_res, ""],
        "F_stat": [F_stat, "", ""],
        "p-value": [p_value, "", ""]
    })
```

Partie 4 : Comparaison des 3 Méthodes

Tâches demandées

- Comparer les coefficients estimés.
- Comparer les valeurs de R^2.
- Comparer les tableaux ANOVA.
- Interpréter les résultats.

Code à compléter : comparaison des coefficients

```
from sklearn.metrics import r2_score

coefficients_sm = ______________________
coefficients_sklearn = np.append(____________________, ____________________)
coefficients_mco = ______________________

comparison_df = pd.DataFrame({
    'Statsmodels': coefficients_sm,
    'Sklearn': coefficients_sklearn,
    'Moindres Carrés': coefficients_mco
}, index=['Intercept'] + list(X.columns))

print(comparison_df)
```

Correction : comparaison des coefficients

```
from sklearn.metrics import r2_score

coefficients_sm = model_sm.params
coefficients_sklearn = np.append(model_sklearn.intercept_, model_sklearn.coef_)
coefficients_mco = beta_mco.flatten()

comparison_df = pd.DataFrame({
    'Statsmodels': coefficients_sm,
    'Sklearn': coefficients_sklearn,
    'Moindres Carrés': coefficients_mco
}, index=['Intercept'] + list(X.columns))

print(comparison_df)
```

Sortie affichée : coefficients comparés

	Statsmodels	Sklearn	Moindres Carrés
Intercept	36.459488	36.459488	36.459488
crim	-0.108011	-0.108011	-0.108011
zn	0.046420	0.046420	0.046420
indus	0.020559	0.020559	0.020559
chas	2.686734	2.686734	2.686734
nox	-17.766611	-17.766611	-17.766611
rm	3.809865	3.809865	3.809865
age	0.000692	0.000692	0.000692
dis	-1.475567	-1.475567	-1.475567
rad	0.306049	0.306049	0.306049
tax	-0.012335	-0.012335	-0.012335
ptratio	-0.952747	-0.952747	-0.952747
lstat	-0.524758	-0.524758	-0.524758

Code à compléter : calcul de R^2

```
r2_mco = r2_score(Y, ______________________)

print("Statsmodels R² :", ______________________)
print("Sklearn R² :", ______________________)
print("Moindres Carrés R² :", ______________________)
```

Correction : calcul de R^2

```
r2_mco = r2_score(Y, Y_pred_mco)

print("Statsmodels R² :", model_sm.rsquared)
print("Sklearn R² :", r2_score(Y, model_sklearn.predict(X)))
print("Moindres Carrés R² :", r2_mco)
```

Sortie affichée : R^2

```
Statsmodels R² : 0.7343070437613076
Sklearn R² : 0.7343070437613076
Moindres Carrés R² : 0.7343070437613076
```

Code à compléter : tableaux ANOVA

```
from tabulate import tabulate
import statsmodels.api as sm

anova_mco = compute_anova(Y, ___________________, X.shape[0], X.shape[1])
anova_sklearn = compute_anova(Y, ___________________, X.shape[0], X.shape[1])
anova_sm = sm.stats.anova_lm(___________________, typ=1)

print(tabulate(anova_mco, headers="keys", tablefmt="grid", showindex=False, floatfmt=".4f")
print(tabulate(anova_sklearn, headers="keys", tablefmt="grid", showindex=False, floatfmt="
print(tabulate(anova_sm, headers="keys", tablefmt="grid", floatfmt=".4f"))
```

Correction : tableaux ANOVA

```
from tabulate import tabulate
import statsmodels.api as sm

anova_mco = compute_anova(Y, Y_pred_mco, X.shape[0], X.shape[1])
anova_sklearn = compute_anova(Y, Y_pred_sklearn, X.shape[0], X.shape[1])
anova_sm = sm.stats.anova_lm(model_sm, typ=1)

print(tabulate(anova_mco, headers="keys", tablefmt="grid", showindex=False, floatfmt=".4f")
print(tabulate(anova_sklearn, headers="keys", tablefmt="grid", showindex=False, floatfmt="
print(tabulate(anova_sm, headers="keys", tablefmt="grid", floatfmt=".4f"))
```

Figures : comparaison des ANOVA

Tableau ANOVA avec la formule des Moindres Carrés Ordinaires (MCO)

Source	Somme des Carrés (SC)	Degrés de Liberté (dl)	Moyenne des Carrés (MC)	F_stat	p-value
Régression	31366.8766	12	2613.9063838863754	113.543774268359	1.1102230246251565e-16
Résiduel	11349.4188	493	23.021133485561673		
Total	42716.2954	505			

Tableau ANOVA avec `LinearRegression` de sklearn

Source	Somme des Carrés (SC)	Degrés de Liberté (dl)	Moyenne des Carrés (MC)	F_stat	p-value
Régression	31366.8766	12	2613.9063838864613	113.54377426836275	1.1102230246251565e-16
Résiduel	11349.4188	493	23.02113348556167		
Total	42716.2954	505			

Tableau ANOVA avec `OLS` de statsmodels

	df	sum_sq	mean_sq	F	PR(>F)
crim	1.0000	6440.7831	6440.7831	279.7770	0.0000
zn	1.0000	3554.3362	3554.3362	154.3945	0.0000
indus	1.0000	2551.2364	2551.2364	110.8215	0.0000
chas	1.0000	1529.8479	1529.8479	66.4541	0.0000
nox	1.0000	76.2476	76.2476	3.3121	0.0694
rm	1.0000	10938.1166	10938.1166	475.1337	0.0000
age	1.0000	90.2679	90.2679	3.9211	0.0482
dis	1.0000	1779.5011	1779.5011	77.2986	0.0000
rad	1.0000	34.1343	34.1343	1.4827	0.2239
tax	1.0000	329.5541	329.5541	14.3153	0.0002
ptratio	1.0000	1309.3093	1309.3093	56.8742	0.0000
lstat	1.0000	2733.5420	2733.5420	118.7405	0.0000
Residual	493.0000	11349.4188	23.0211	nan	nan

Interprétation guidée des résultats

- Les trois méthodes donnent les mêmes coefficients.
- Les trois méthodes donnent le même R^2.
- Cela confirme que les trois approches estiment le même modèle linéaire multiple.

Question

Que signifie un $R^2 \approx 0.7343$?

Réponse

Environ 73.43% de la variabilité de `medv` est expliquée par le modèle.

Interprétation guidée des coefficients

- Un coefficient positif indique qu'une augmentation du prédicteur est associée à une augmentation de `medv`, toutes choses égales par ailleurs.
- Un coefficient négatif indique l'effet inverse.

Exemples

- `rm` a un coefficient positif : plus le nombre moyen de pièces est élevé, plus la valeur médiane tend à augmenter.
- `nox` a un coefficient négatif : une hausse de la pollution est associée à une baisse du prix des logements.
- `lstat` a un coefficient négatif : une hausse de cette variable est associée à une diminution de `medv`.

Discussion guidée

- Les tableaux ANOVA globaux de MCO et `sklearn` coïncident.
- La méthode `anova_lm` de `statsmodels` décompose l'ANOVA variable par variable.
- Cela permet d'identifier quelles variables contribuent significativement au modèle.

À retenir

- Le dataset Boston Housing permet d'appliquer concrètement la régression multiple.
- La formule analytique des MCO, `LinearRegression` et `OLS` donnent ici les mêmes résultats globaux.
- Le tableau ANOVA permet de juger la significativité globale du modèle.
- L'ANOVA détaillée de `statsmodels` aide à étudier la contribution individuelle des variables.

Table des Matières

1. Régression Linéaire Multiple
2. Décomposition de la Variabilité Totale
3. ANOVA en Régression Linéaire Multiple
4. Exercice : Boston Housing Prices Dataset
5. Intervalle de Confiance et Intervalle de Prédiction
6. Annexe

Intervalle de Confiance pour la Réponse Moyenne et Intervalle de Prédiction pour une Nouvelle Observation

Question de départ

Comment peut-on quantifier notre incertitude sur une estimation ?

Idée intuitive

- On exprime ce que l'on cherche sous forme probabiliste.
- On utilise l'erreur standard pour quantifier l'incertitude.
- On en déduit un intervalle à partir d'une loi de référence.

Intervalle de Confiance pour la Réponse Moyenne

QCM : que cherche-t-on à encadrer ?

Lorsqu'on considère une nouvelle valeur observée

$$\mathbf{X}_0 = \boldsymbol{x}_0,$$

que cherche-t-on à encadrer avec un **intervalle de confiance** ?

A. la nouvelle observation Y_0
B. la moyenne conditionnelle $\mathbb{E}[Y \mid \mathbf{X}_0 = \boldsymbol{x}_0]$
C. la variance de Y
D. le résidu e_0

QCM : corrigé sur l'IC

Bonne réponse : B

L'intervalle de confiance encadre la **réponse moyenne** du modèle pour

$$\mathbf{X}_0 = \boldsymbol{x}_0,$$

c'est-à-dire

$$\mathbb{E}[Y \mid \mathbf{X}_0 = \boldsymbol{x}_0].$$

Notation

On note souvent

$$\hat{Y}_0 = \boldsymbol{x}_0^\top \hat{\boldsymbol{\beta}}$$

la valeur prédite, et l'on cherche à quantifier l'incertitude sur la moyenne correspondante.

Formulation probabiliste pour l'IC

Sous les hypothèses du modèle, on a

$$\frac{\hat{Y}_0 - \mathbb{E}[Y_0]}{\mathrm{SE}(\hat{Y}_0)} = \frac{\hat{Y}_0 - \mathbb{E}[Y \mid \mathbf{X}_0 = \boldsymbol{x}_0]}{s\sqrt{\boldsymbol{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \boldsymbol{x}_0}} \sim t_{n-p-1}.$$

Erreur standard de la réponse moyenne prédite

$$\mathrm{SE}(\hat{Y}_0) = s\sqrt{\boldsymbol{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \boldsymbol{x}_0}.$$

QCM : forme de l'intervalle de confiance

À partir de

$$P\left(-t_{\alpha/2,n-p-1} \leq \frac{\hat{Y}_0 - \mathbb{E}[Y_0]}{\mathrm{SE}(\hat{Y}_0)} \leq t_{\alpha/2,n-p-1}\right) = 1-\alpha,$$

quelle est la forme correcte de l'intervalle de confiance à $100(1-\alpha)\%$?

A.

$$\hat{Y}_0 \pm t_{\alpha/2,n-p-1}\,\mathrm{SE}(\hat{Y}_0)$$

B.

$$Y_0 \pm t_{\alpha/2,n-p-1}\,\mathrm{SE}(Y_0)$$

C.

$$\hat{Y}_0 \pm z_{\alpha/2}\,\sigma$$

D.

$$\bar{Y} \pm t_{\alpha/2,n-p-1}\,\mathrm{SE}(\hat{Y}_0)$$

QCM : corrigé sur la forme de l'IC

Bonne réponse : A

L'intervalle de confiance à $100(1-\alpha)\%$ pour la réponse moyenne est

$$\hat{Y}_0 \pm t_{\alpha/2,n-p-1}\,\mathrm{SE}(\hat{Y}_0).$$

Interprétation

Il s'agit d'un intervalle pour la **moyenne conditionnelle** de la réponse, et non pour une nouvelle observation individuelle.

Intervalle de Prédiction pour une Nouvelle Observation

QCM : que cherche-t-on à encadrer ?

Lorsqu'on construit un **intervalle de prédiction**, que cherche-t-on à encadrer ?

A. uniquement la moyenne $\mathbb{E}[Y \mid \mathbf{X}_0 = \boldsymbol{x}_0]$
B. la nouvelle observation Y_0
C. uniquement l'erreur ε_0
D. uniquement l'intercept β_0

QCM : corrigé sur l'IP

Bonne réponse : B

L'intervalle de prédiction encadre une **nouvelle observation individuelle**

$$Y_0$$

pour

$$\mathbf{X}_0 = \boldsymbol{x}_0.$$

Idée

Ici, on ne quantifie pas seulement l'incertitude sur la moyenne estimée, mais aussi la variabilité intrinsèque des nouvelles observations.

Formulation probabiliste pour l'IP

Sous les hypothèses du modèle, on a

$$\frac{Y_0 - \hat{Y}_0}{\mathrm{SE}(Y_0 - \hat{Y}_0)} = \frac{Y_0 - \hat{Y}_0}{s\sqrt{1 + \boldsymbol{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \boldsymbol{x}_0}} \sim t_{n-p-1}.$$

Erreur standard de prédiction

$$\mathrm{SE}(Y_0 - \hat{Y}_0) = s\sqrt{1 + \boldsymbol{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \boldsymbol{x}_0}.$$

QCM : forme de l'intervalle de prédiction

Quelle est la forme correcte de l'intervalle de prédiction à $100(1-\alpha)\%$?

A.
$$\hat{Y}_0 \pm t_{\alpha/2,n-p-1}\,\mathrm{SE}(\hat{Y}_0)$$

B.
$$\hat{Y}_0 \pm t_{\alpha/2,n-p-1}\,\mathrm{SE}(Y_0-\hat{Y}_0)$$

C.
$$Y_0 \pm t_{\alpha/2,n-p-1}\,\mathrm{SE}(Y_0)$$

D.
$$\bar{Y} \pm t_{\alpha/2,n-p-1}\,\mathrm{SE}(Y_0-\hat{Y}_0)$$

QCM : corrigé sur la forme de l'IP

Bonne réponse : B

L'intervalle de prédiction à $100(1-\alpha)\%$ pour une nouvelle observation est

$$\hat{Y}_0 \pm t_{\alpha/2,n-p-1}\,\mathrm{SE}(Y_0 - \hat{Y}_0).$$

Pourquoi est-il plus large ?

Parce qu'il inclut à la fois :

- l'incertitude sur la moyenne estimée ;
- la variabilité aléatoire propre à une nouvelle observation.

Comparaison : IC vs IP

- **Intervalle de confiance (IC)** :
  - encadre la moyenne $\mathbb{E}[Y \mid \mathbf{X}_0 = \boldsymbol{x}_0]$;
  - reflète l'incertitude sur la moyenne estimée.
- **Intervalle de prédiction (IP)** :
  - encadre une nouvelle observation Y_0 ;
  - inclut la variabilité supplémentaire des observations individuelles.

À retenir

L'intervalle de prédiction est toujours plus large que l'intervalle de confiance.

Exercice illustratif : Régression Linéaire Simple

Objectif

- Utiliser uniquement la variable `rm` pour prédire `medv`.
- Calculer les intervalles de confiance et de prédiction.
- Comparer leur largeur pour quelques valeurs test de `rm`.
- Visualiser les bandes IC et IP sur un graphique.

Code à compléter : préparation du modèle simple

```
import numpy as np
import pandas as pd
import scipy.stats as stats
import matplotlib.pyplot as plt
import statsmodels.api as sm
import seaborn as sns
from ISLP import load_data

sns.set_theme()

Boston = load_data('Boston')

# Sélection de RM comme unique prédicteur
X = Boston[[________]]
Y = Boston['______'].values

# Ajouter l'intercept
X_with_intercept = sm.____________(X)

# Ajuster le modèle
model = sm.OLS(Y, _______________________).fit()

# Prédictions sur l'échantillon
Y_pred = model.____________________
```

Correction : préparation du modèle simple

```
import numpy as np
import pandas as pd
import scipy.stats as stats
import matplotlib.pyplot as plt
import statsmodels.api as sm
import seaborn as sns
from ISLP import load_data

sns.set_theme()

Boston = load_data('Boston')

X = Boston[['rm']]
Y = Boston['medv'].values

X_with_intercept = sm.add_constant(X)

model = sm.OLS(Y, X_with_intercept).fit()

Y_pred = model.predict(X_with_intercept)
```

Code à compléter : paramètres statistiques

```
n = len(X)

s_squared = np.sum((________________________) ** 2) / (n - 2)
s = np.sqrt(s_squared)

t_value = stats.t.ppf(1 - 0.025, df=_______)

XTX_inv = np.linalg.inv(_____________________________)
```

Correction : paramètres statistiques

```
n = len(X)

s_squared = np.sum((Y - Y_pred) ** 2) / (n - 2)
s = np.sqrt(s_squared)

t_value = stats.t.ppf(1 - 0.025, df=n - 2)

XTX_inv = np.linalg.inv(X_with_intercept.T @ X_with_intercept)
```

Code à compléter : calcul des IC et IP

```
rm_values = np.linspace(X['rm'].min(), X['rm'].max(), 100)
X_range = sm.add_constant(pd.DataFrame({'rm': rm_values}))

IC_inf, IC_sup, IP_inf, IP_sup = [], [], [], []

for x_0 in X_range.values:
    variance_IC = s_squared * (_____________________________)
    variance_IP = s_squared * (_____________________________)

    SE_IC = np.sqrt(variance_IC)
    SE_IP = np.sqrt(variance_IP)

    y_hat = model.predict([x_0])[0]

    IC_inf.append(_____________________________)
    IC_sup.append(_____________________________)
    IP_inf.append(_____________________________)
    IP_sup.append(_____________________________)
```

Correction : calcul des IC et IP

```
rm_values = np.linspace(X['rm'].min(), X['rm'].max(), 100)
X_range = sm.add_constant(pd.DataFrame({'rm': rm_values}))

IC_inf, IC_sup, IP_inf, IP_sup = [], [], [], []

for x_0 in X_range.values:
    variance_IC = s_squared * (x_0 @ XTX_inv @ x_0.T)
    variance_IP = s_squared * (1 + x_0 @ XTX_inv @ x_0.T)

    SE_IC = np.sqrt(variance_IC)
    SE_IP = np.sqrt(variance_IP)

    y_hat = model.predict([x_0])[0]

    IC_inf.append(y_hat - t_value * SE_IC)
    IC_sup.append(y_hat + t_value * SE_IC)
    IP_inf.append(y_hat - t_value * SE_IP)
    IP_sup.append(y_hat + t_value * SE_IP)
```

Code à compléter : points de test

```
rm_test_values = np.array([5, 6, 7, 8])
test_points = sm.add_constant(pd.DataFrame({'rm': rm_test_values}))
test_pred = model.predict(test_points)

test_IC = []
test_IP = []

for x_0 in test_points.values:
    variance_IC = s_squared * (__________________________)
    variance_IP = s_squared * (__________________________)

    SE_IC = np.sqrt(variance_IC)
    SE_IP = np.sqrt(variance_IP)

    test_IC.append(__________________________)
    test_IP.append(__________________________)

for i, rm_val in enumerate(rm_test_values):
    print(f"Prédiction pour RM = {rm_val} : {test_pred[i]:.2f}")
    print(f"IC à 95%: [{test_pred[i] - test_IC[i]:.2f}, {test_pred[i] + test_IC[i]:.2f}]")
    print(f"IP à 95%: [{test_pred[i] - test_IP[i]:.2f}, {test_pred[i] + test_IP[i]:.2f}]")
    print("-" * 50)
```

Correction : points de test

```
rm_test_values = np.array([5, 6, 7, 8])
test_points = sm.add_constant(pd.DataFrame({'rm': rm_test_values}))
test_pred = model.predict(test_points)

test_IC = []
test_IP = []

for x_0 in test_points.values:
    variance_IC = s_squared * (x_0 @ XTX_inv @ x_0.T)
    variance_IP = s_squared * (1 + x_0 @ XTX_inv @ x_0.T)

    SE_IC = np.sqrt(variance_IC)
    SE_IP = np.sqrt(variance_IP)

    test_IC.append(t_value * SE_IC)
    test_IP.append(t_value * SE_IP)

for i, rm_val in enumerate(rm_test_values):
    print(f"Prédiction pour RM = {rm_val} : {test_pred[i]:.2f}")
    print(f"IC à 95%: [{test_pred[i] - test_IC[i]:.2f}, {test_pred[i] + test_IC[i]:.2f}]")
    print(f"IP à 95%: [{test_pred[i] - test_IP[i]:.2f}, {test_pred[i] + test_IP[i]:.2f}]")
    print("-" * 50)
```

Sortie affichée : régression simple

```
Prédiction pour RM = 5 : 10.84
IC à 95%: [9.63, 12.05]
IP à 95%: [-2.21, 23.89]
--------------------------------------------------
Prédiction pour RM = 6 : 19.94
IC à 95%: [19.32, 20.57]
IP à 95%: [6.93, 32.96]
--------------------------------------------------
Prédiction pour RM = 7 : 29.04
IC à 95%: [28.22, 29.87]
IP à 95%: [16.02, 42.07]
--------------------------------------------------
Prédiction pour RM = 8 : 38.15
IC à 95%: [36.62, 39.67]
IP à 95%: [25.06, 51.23]
--------------------------------------------------
```

Code à compléter : tracé des bandes IC et IP

```
plt.figure(figsize=(8, 6))
plt.scatter(X['rm'], Y, label="Données réelles", color='blue', alpha=0.5)
plt.plot(rm_values, model.predict(X_range), label="Régression linéaire", color='black')

plt.fill_between(rm_values, ____________, ____________, color='green', alpha=0.3,
                 label="Intervalle de confiance (95%)")
plt.fill_between(rm_values, ____________, ____________, color='red', alpha=0.2,
                 label="Intervalle de prédiction (95%)")

plt.errorbar(rm_test_values, test_pred, yerr=__________, fmt='o', color='red',
             label="IP (points test)")
plt.errorbar(rm_test_values, test_pred, yerr=__________, fmt='o', color='green',
             label="IC (points test)")

plt.xlabel("Nombre moyen de pièces (RM)")
plt.ylabel("Valeur médiane des logements (MEDV)")
plt.legend()
plt.title("Régression linéaire avec IC et IP en fonction du nombre de pièces")
plt.show()
```

Correction : tracé des bandes IC et IP

```
plt.figure(figsize=(8, 6))
plt.scatter(X['rm'], Y, label="Données réelles", color='blue', alpha=0.5)
plt.plot(rm_values, model.predict(X_range), label="Régression linéaire", color='black')

plt.fill_between(rm_values, IC_inf, IC_sup, color='green', alpha=0.3,
                 label="Intervalle de confiance (95%)")
plt.fill_between(rm_values, IP_inf, IP_sup, color='red', alpha=0.2,
                 label="Intervalle de prédiction (95%)")

plt.errorbar(rm_test_values, test_pred, yerr=test_IP, fmt='o', color='red',
             label="IP (points test)")
plt.errorbar(rm_test_values, test_pred, yerr=test_IC, fmt='o', color='green',
             label="IC (points test)")

plt.xlabel("Nombre moyen de pièces (RM)")
plt.ylabel("Valeur médiane des logements (MEDV)")
plt.legend()
plt.title("Régression linéaire avec IC et IP en fonction du nombre de pièces")
plt.show()
```

Régression simple : figure IC et IP

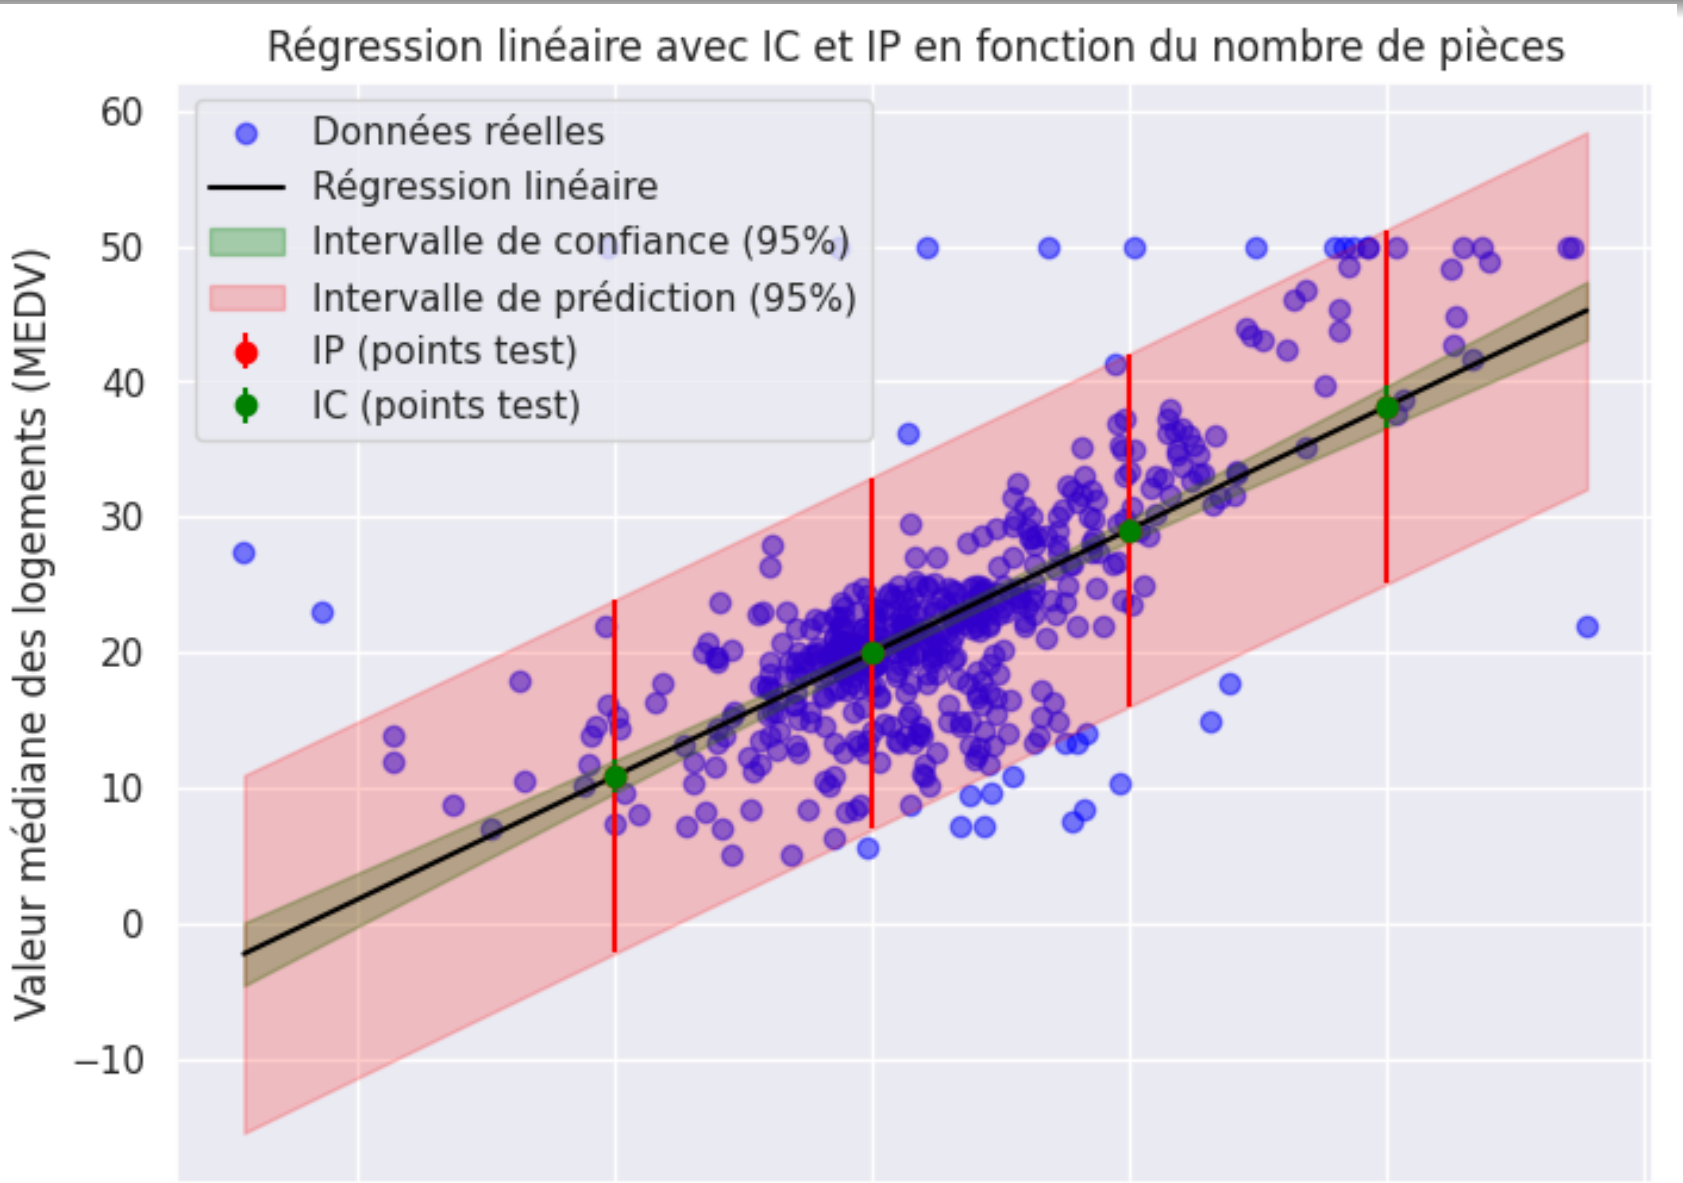

Interprétation de la figure : régression simple

- La tendance générale montre que plus le nombre moyen de pièces (`RM`) est élevé, plus la valeur médiane des logements tend à être élevée.
- L'intervalle de confiance (en vert) est plus étroit, car il encadre la moyenne estimée.
- L'intervalle de prédiction (en rouge) est plus large, car il doit aussi tenir compte de la variabilité individuelle des logements.
- L'incertitude est plus faible dans les zones où l'on dispose de plus d'observations, et plus grande aux extrémités.

Exercice illustratif : Régression Linéaire Multiple

Objectif

- Utiliser toutes les variables disponibles pour prédire `medv`.
- Tracer la relation entre `rm` et `medv` en gardant les autres variables fixées à leur moyenne.
- Comparer les IC et IP obtenus avec ceux de la régression simple.

Code à compléter : préparation du modèle multiple

```
import numpy as np
import pandas as pd
import scipy.stats as stats
import matplotlib.pyplot as plt
import statsmodels.api as sm
import seaborn as sns
from ISLP import load_data

sns.set_theme()

Boston = load_data('Boston')

X = Boston.drop(columns=['______'])
Y = Boston['______'].values

X_with_intercept = sm.add_constant(X)

model = sm.OLS(Y, ______________________).fit()
Y_pred = model.____________________

n, p = X.shape
s_squared = np.sum((______________________) ** 2) / (n - p - 1)
t_value = stats.t.ppf(1 - 0.025, df=_________________)
XTX_inv = np.linalg.inv(____________________________________)
```

Correction : préparation du modèle multiple

```
import numpy as np
import pandas as pd
import scipy.stats as stats
import matplotlib.pyplot as plt
import statsmodels.api as sm
import seaborn as sns
from ISLP import load_data

sns.set_theme()

Boston = load_data('Boston')

X = Boston.drop(columns=['medv'])
Y = Boston['medv'].values

X_with_intercept = sm.add_constant(X)

model = sm.OLS(Y, X_with_intercept).fit()
Y_pred = model.predict(X_with_intercept)

n, p = X.shape
s_squared = np.sum((Y - Y_pred) ** 2) / (n - p - 1)
t_value = stats.t.ppf(1 - 0.025, df=n - p - 1)
XTX_inv = np.linalg.inv(X_with_intercept.T @ X_with_intercept)
```

Code à compléter : construire une courbe selon RM

```
rm_values = np.linspace(X["rm"].min(), X["rm"].max(), 100)

X_range = np.tile(X.mean(axis=0), (100, 1))
X_range[:, X.columns.get_loc('rm')] = ______________

X_range_df = pd.DataFrame(X_range, columns=X.columns)

X_range_with_intercept = np.c_[______________________, X_range_df]
X_range_with_intercept = pd.DataFrame(
    X_range_with_intercept, columns=X_with_intercept.columns
)
```

Correction : construire une courbe selon RM

```
rm_values = np.linspace(X["rm"].min(), X["rm"].max(), 100)

X_range = np.tile(X.mean(axis=0), (100, 1))
X_range[:, X.columns.get_loc('rm')] = rm_values

X_range_df = pd.DataFrame(X_range, columns=X.columns)

X_range_with_intercept = np.c_[np.ones(X_range_df.shape[0]), X_range_df]
X_range_with_intercept = pd.DataFrame(
    X_range_with_intercept, columns=X_with_intercept.columns
)
```

Code à compléter : calcul des bandes IC et IP

```
IC_inf, IC_sup, IP_inf, IP_sup = [], [], [], []

for x_0 in X_range_with_intercept.values:
    x_0 = x_0.reshape(1, -1)

    variance_IC = s_squared * (__________________________)[0][0]
    variance_IP = s_squared * (__________________________)[0][0]

    SE_IC = np.sqrt(variance_IC)
    SE_IP = np.sqrt(variance_IP)

    y_hat = model.predict(x_0)[0]

    IC_inf.append(__________________________)
    IC_sup.append(__________________________)
    IP_inf.append(__________________________)
    IP_sup.append(__________________________)
```

Correction : calcul des bandes IC et IP

```
IC_inf, IC_sup, IP_inf, IP_sup = [], [], [], []

for x_0 in X_range_with_intercept.values:
    x_0 = x_0.reshape(1, -1)

    variance_IC = s_squared * (x_0 @ XTX_inv @ x_0.T)[0][0]
    variance_IP = s_squared * (1 + x_0 @ XTX_inv @ x_0.T)[0][0]

    SE_IC = np.sqrt(variance_IC)
    SE_IP = np.sqrt(variance_IP)

    y_hat = model.predict(x_0)[0]

    IC_inf.append(y_hat - t_value * SE_IC)
    IC_sup.append(y_hat + t_value * SE_IC)
    IP_inf.append(y_hat - t_value * SE_IP)
    IP_sup.append(y_hat + t_value * SE_IP)
```

Code à compléter : points de test en régression multiple

```
rm_test_values = np.array([5, 6, 7, 8])

test_X = np.tile(X.mean(axis=0), (len(rm_test_values), 1))
test_X[:, X.columns.get_loc('rm')] = _______________________

test_X_df = pd.DataFrame(test_X, columns=X.columns)

test_X_with_intercept = np.c_[_____________________, test_X_df]
test_X_with_intercept = pd.DataFrame(
    test_X_with_intercept, columns=X_with_intercept.columns
)

test_pred = model.predict(test_X_with_intercept)

test_IC = []
test_IP = []

for x_0 in test_X_with_intercept.values:
    variance_IC = s_squared * (__________________________)
    variance_IP = s_squared * (__________________________)

    SE_IC = np.sqrt(variance_IC)
    SE_IP = np.sqrt(variance_IP)

    test_IC.append(__________________________)
    test_IP.append(__________________________)
```

Correction : points de test en régression multiple

```
rm_test_values = np.array([5, 6, 7, 8])

test_X = np.tile(X.mean(axis=0), (len(rm_test_values), 1))
test_X[:, X.columns.get_loc('rm')] = rm_test_values

test_X_df = pd.DataFrame(test_X, columns=X.columns)

test_X_with_intercept = np.c_[np.ones(test_X_df.shape[0]), test_X_df]
test_X_with_intercept = pd.DataFrame(
    test_X_with_intercept, columns=X_with_intercept.columns
)

test_pred = model.predict(test_X_with_intercept)

test_IC = []
test_IP = []

for x_0 in test_X_with_intercept.values:
    variance_IC = s_squared * (x_0 @ XTX_inv @ x_0.T)
    variance_IP = s_squared * (1 + x_0 @ XTX_inv @ x_0.T)

    SE_IC = np.sqrt(variance_IC)
    SE_IP = np.sqrt(variance_IP)

    test_IC.append(t_value * SE_IC)
    test_IP.append(t_value * SE_IP)
```

Sortie affichée : régression multiple

```
Prédiction pour RM = 5 : 17.83
IC à 95%: [16.69, 18.97]
IP à 95%: [8.34, 27.33]
--------------------------------------------------
Prédiction pour RM = 6 : 21.49
IC à 95%: [21.01, 21.97]
IP à 95%: [12.05, 30.93]
--------------------------------------------------
Prédiction pour RM = 7 : 25.15
IC à 95%: [24.43, 25.87]
IP à 95%: [15.69, 34.60]
--------------------------------------------------
Prédiction pour RM = 8 : 28.81
IC à 95%: [27.33, 30.28]
IP à 95%: [19.27, 38.35]
--------------------------------------------------
```

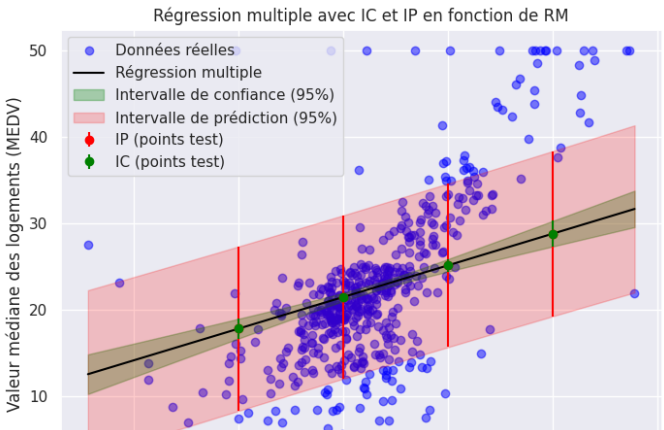

Code à compléter : tracé en régression multiple

```
plt.figure(figsize=(8, 6))
plt.scatter(X["rm"], Y, label="Données réelles", color='blue', alpha=0.5)
plt.plot(rm_values, model.predict(X_range_with_intercept),
         label="Régression multiple", color='black')

plt.fill_between(rm_values, ____________, ____________, color='green', alpha=0.3,
                 label="Intervalle de confiance (95%)")
plt.fill_between(rm_values, ____________, ____________, color='red', alpha=0.2,
                 label="Intervalle de prédiction (95%)")

plt.errorbar(rm_test_values, test_pred, yerr=__________, fmt='o', color='red',
             label="IP (points test)")
plt.errorbar(rm_test_values, test_pred, yerr=__________, fmt='o', color='green',
             label="IC (points test)")

plt.xlabel("Nombre moyen de pièces (RM)")
plt.ylabel("Valeur médiane des logements (MEDV)")
plt.legend()
plt.title("Régression multiple avec IC et IP en fonction de RM")
plt.show()
```

Correction : tracé en régression multiple

```
plt.figure(figsize=(8, 6))
plt.scatter(X["rm"], Y, label="Données réelles", color='blue', alpha=0.5)
plt.plot(rm_values, model.predict(X_range_with_intercept),
         label="Régression multiple", color='black')

plt.fill_between(rm_values, IC_inf, IC_sup, color='green', alpha=0.3,
                 label="Intervalle de confiance (95%)")
plt.fill_between(rm_values, IP_inf, IP_sup, color='red', alpha=0.2,
                 label="Intervalle de prédiction (95%)")

plt.errorbar(rm_test_values, test_pred, yerr=test_IP, fmt='o', color='red',
             label="IP (points test)")
plt.errorbar(rm_test_values, test_pred, yerr=test_IC, fmt='o', color='green',
             label="IC (points test)")

plt.xlabel("Nombre moyen de pièces (RM)")
plt.ylabel("Valeur médiane des logements (MEDV)")
plt.legend()
plt.title("Régression multiple avec IC et IP en fonction de RM")
plt.show()
```

Régression multiple : figure IC et IP

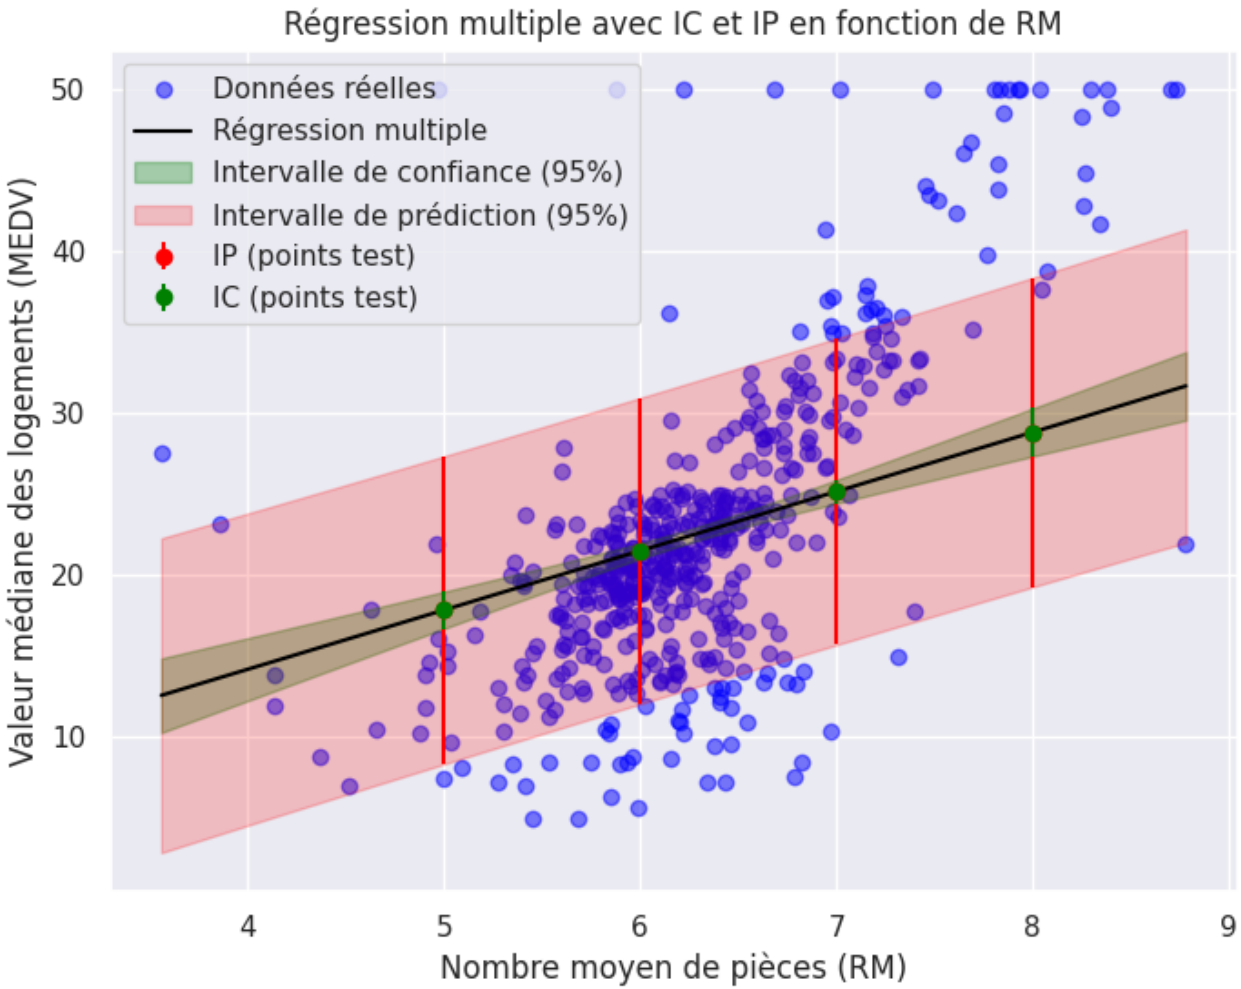

Interprétation de la figure : régression multiple

- Ici, on utilise toutes les variables explicatives pour prédire `medv`.
- On ne trace cependant la relation qu'en fonction de `rm`, en gardant les autres variables fixées à leur moyenne.
- Les intervalles sont souvent plus étroits qu'en régression simple, car le modèle multiple explique mieux la variabilité de `medv`.

Figure du cours : pourquoi les prédictions sont-elles dispersées ?

- Le modèle est une **régression multiple** : deux observations avec la même valeur de `rm` peuvent avoir des prédictions différentes à cause des autres variables explicatives.
- Le graphique ne montre qu'une **projection** d'un modèle multidimensionnel sur l'axe de `rm`.
- Les croix noires correspondent à des prédictions qui utilisent les vraies valeurs des autres variables, pas leur moyenne.

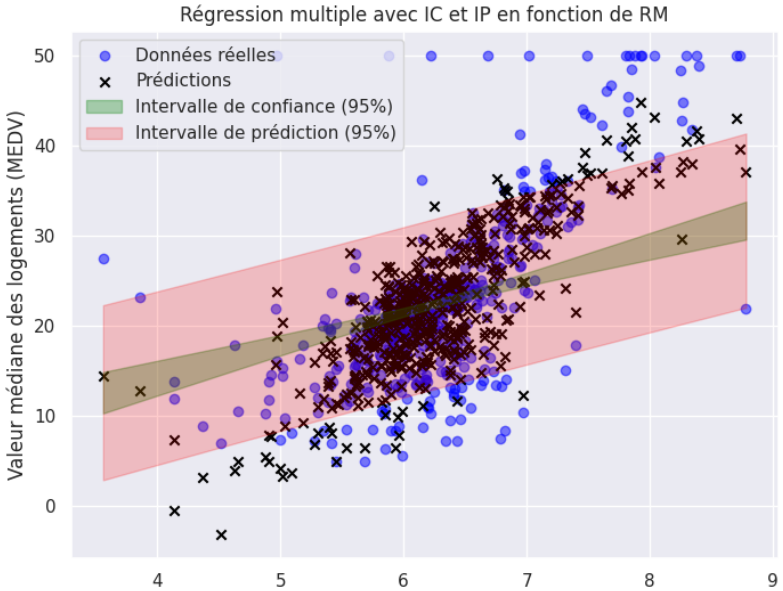

Figure du cours : lecture des intervalles

- Même si les prédictions individuelles sont dispersées, les bandes IC et IP gardent une structure claire.
- L'intervalle de confiance représente l'incertitude sur la moyenne estimée.
- L'intervalle de prédiction reflète la variabilité des observations individuelles ; il est donc plus large.

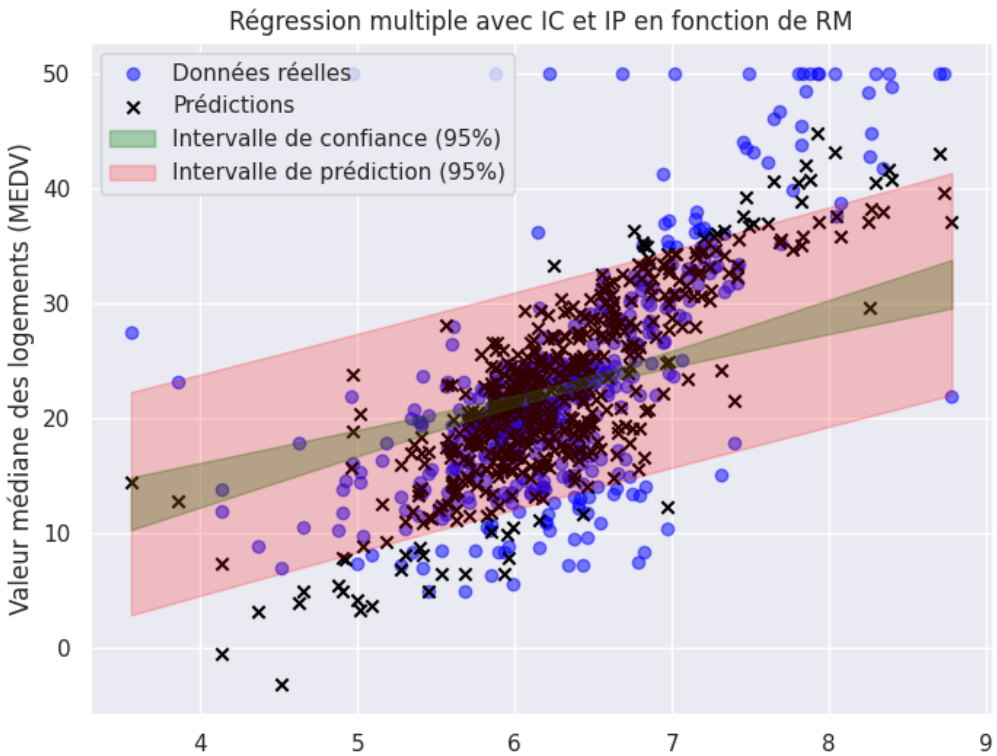

Conclusion visuelle

- Le graphe illustre une relation simplifiée entre `MEDV` et `RM`.
- En réalité, la valeur des logements dépend de plusieurs facteurs simultanément.
- La dispersion des prédictions n'est pas une erreur : elle reflète simplement la complexité du modèle et l'influence des autres variables explicatives.

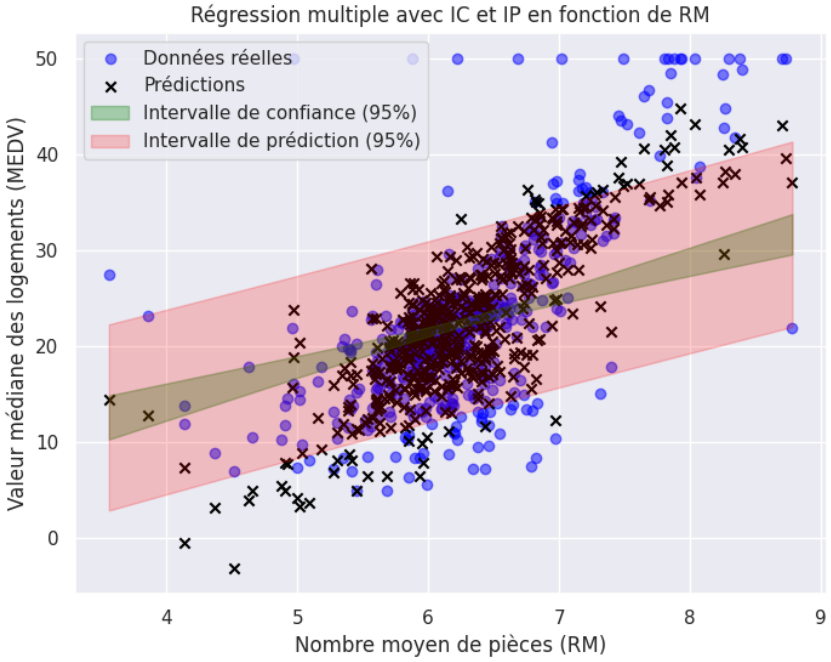

Résumé : IC et IP

- **IC** : intervalle de confiance $\rightarrow$ incertitude sur la réponse moyenne estimée.
- **IP** : intervalle de prédiction $\rightarrow$ incertitude sur une nouvelle observation.
- En général, l'IP est plus large que l'IC.
- En régression multiple, la visualisation d'une seule variable explicative correspond à une projection d'un modèle plus complexe.
- Dans les deux cas, les intervalles tendent à s'élargir dans les zones où l'incertitude est plus grande.

Merci!

E-mail: chiheb.trabelsi@polymtl.ca

Table des Matières

1. Régression Linéaire Multiple
2. Décomposition de la Variabilité Totale
3. ANOVA en Régression Linéaire Multiple
4. Exercice : Boston Housing Prices Dataset
5. Intervalle de Confiance et Intervalle de Prédiction
6. Annexe

Matrice de Gram $\mathbf{X}^\top\mathbf{X}$

Matrice de Gram $\mathbf{X}^\top\mathbf{X}$

- Une **matrice de Gram** est une matrice symétrique qui contient les produits scalaires entre ses vecteurs et permet d'analyser leur dépendance linéaire.
- Soit $\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_m$ un ensemble de m vecteurs dans un espace de dimension n.
- La **matrice de Gram** associée à ces vecteurs est définie par :

$$\mathbf{G} = \mathbf{X}^\top\mathbf{X}$$

où $\mathbf{X}$ est la matrice dont les colonnes sont les vecteurs $\mathbf{x}_i$, soit :

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_m \end{bmatrix}$$

- La matrice de Gram $\mathbf{G}$ a donc pour éléments :

$$G_{ij} = \mathbf{x}_i^\top \mathbf{x}_j$$

Matrice de Gram $\mathbf{X}^\top\mathbf{X}$

- **Matrice symétrique** :

$$G_{ij} = \mathbf{x}_i^\top \mathbf{x}_j = \mathbf{x}_j^\top \mathbf{x}_i = G_{ji}$$

ce qui implique que $\mathbf{G}$ est toujours symétrique.

- **Définie positive ou semi-définie positive** :
  - Si les vecteurs $\mathbf{x}_i$ sont **linéairement indépendants**, alors $\mathbf{G}$ est **définie positive**, c'est-à-dire :

$$\forall \quad \mathbf{v} \neq 0, \quad \mathbf{v}^\top \mathbf{G}\mathbf{v} = \mathbf{v}^\top \mathbf{X}^\top \mathbf{X}\mathbf{v} = (\mathbf{X}\mathbf{v})^\top (\mathbf{X}\mathbf{v}) = ||\mathbf{X}\mathbf{v}||_2^2 > 0.$$

  - Si les vecteurs sont **linéairement dépendants**, alors $\mathbf{G}$ est **semi-définie positive** :

$$\exists \mathbf{v} \neq 0 \text{ tel que } \mathbf{v}^\top \mathbf{G}\mathbf{v} = 0.$$

Ce qui implique que $\mathbf{G}$ est non inversible.

Preuve : La Multicolinéarité de $\mathbf{X}$ Implique la Singularité de $\mathbf{X}^\top \mathbf{X}$

Preuve : Multicolinéarité $\Rightarrow$ Singularité de $\mathbf{X}^\top\mathbf{X}$

On considère le modèle de régression linéaire sous forme matricielle :

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$$

où :

- $\boldsymbol{y} \in \mathbb{R}^{n\times 1}$ est le vecteur des observations.
- $\mathbf{X} \in \mathbb{R}^{n\times(p+1)}$ est la matrice des variables explicatives.
- $\boldsymbol{\beta} \in \mathbb{R}^{p\times 1}$ est le vecteur des coefficients.
- $\boldsymbol{\epsilon} \in \mathbb{R}^{n\times 1}$ est le vecteur des erreurs.

Si les variables explicatives sont linéairement dépendantes, alors il existe un ensemble de scalaires $\lambda_1, \lambda_2, \ldots, \lambda_p$, non tous nuls, tels que :

$$\sum_{j=1}^{p} \lambda_j \mathbf{x}_j = \mathbf{0}$$

Preuve : Multicolinéarité $\Rightarrow$ Singularité de $\mathbf{X}^\top\mathbf{X}$

- Si $\mathbf{X}^\top\mathbf{X}$ est inversible, elle doit être de plein rang (rang$(\mathbf{X}^\top\mathbf{X}) = p$).
- Si les colonnes de $\mathbf{X}$ sont linéairement dépendantes, alors il existe un vecteur $\boldsymbol{\lambda} = (\lambda_1, \lambda_2, \ldots, \lambda_p)^\top \neq \mathbf{0}$ tel que :

$$\mathbf{X}\boldsymbol{\lambda} = \mathbf{0}.$$

- cela veut dire que $\boldsymbol{\lambda}$ appartient au **noyau** (**espace nul**) de $\mathbf{X}$ qui est noté par $\ker(\mathbf{X})$
- Le **noyau** (aussi appelé **espace nul**) d'une matrice $\mathbf{A}$ est l'ensemble des vecteurs qui sont envoyés sur le vecteur nul par cette matrice.
- Mathématiquement, le noyau de $\mathbf{A}$ est défini comme :

$$\ker(\mathbf{A}) = \{\mathbf{v} \in \mathbb{R}^p \mid \mathbf{A}\mathbf{v} = \mathbf{0}\}$$

- Autrement dit, le noyau de $\mathbf{A}$ est l'ensemble des solutions de l'équation homogène :

$$\mathbf{A}\mathbf{v} = \mathbf{0}$$

Preuve : Multicolinéarité $\Rightarrow$ Singularité de $\mathbf{X}^\top\mathbf{X}$

- Dans le contexte de la régression linéaire, la matrice des moindres carrés est donnée par :
$$\mathbf{X}^\top\mathbf{X}$$
- Le **noyau** de $\mathbf{X}^\top\mathbf{X}$ est défini comme l'ensemble des vecteurs $\mathbf{v}$ tels que :
$$\ker(\mathbf{X}^\top\mathbf{X}) = \{\mathbf{v} \in \mathbb{R}^p \mid \mathbf{X}^\top\mathbf{X}\mathbf{v} = \mathbf{0}\}$$
- Cela signifie que tout vecteur appartenant au noyau de $\mathbf{X}^\top\mathbf{X}$ est une combinaison linéaire des colonnes de $\mathbf{X}$ qui s'annule lorsqu'on applique $\mathbf{X}^\top\mathbf{X}$.

Preuve que $\mathbf{X}^\top\mathbf{X}$ est singulière si $\mathbf{X}$ est linéairement dépendante

- Si les colonnes de $\mathbf{X}$ sont linéairement dépendantes, alors il existe un vecteur $\boldsymbol{\lambda} = (\lambda_1, \lambda_2, \ldots, \lambda_p)^\top \neq \mathbf{0}$ tel que $\boldsymbol{\lambda} \in \ker(\mathbf{X})$, c'est à dire :

$$\mathbf{X}\boldsymbol{\lambda} = \mathbf{0}.$$

- En multipliant cette expression à gauche par $\mathbf{X}^\top$, on obtient :

$$\mathbf{X}^\top\mathbf{X}\boldsymbol{\lambda} = \mathbf{X}^\top\mathbf{0} = \mathbf{0}$$

- Cela signifie que $\boldsymbol{\lambda}$ appartient au noyau de $\mathbf{X}^\top\mathbf{X}$, donc cette matrice n'est pas inversible.
- Cela signifie que $\ker(\mathbf{X}^\top\mathbf{X})$ contient au moins un vecteur non nul, donc $\mathbf{X}^\top\mathbf{X}$ **n'est pas inversible** CQFD.

Preuve : Multicolinéarité $\Rightarrow$ Singularité de $\mathbf{X}^\top\mathbf{X}$

- Si les colonnes de $\mathbf{X}$ sont **linéairement indépendantes**, alors $\mathbf{X}^\top\mathbf{X}$ est **de plein rang** et son noyau est réduit au vecteur nul :

$$\ker(\mathbf{X}^\top\mathbf{X}) = \{\mathbf{0}\}$$

.

- Si les colonnes de $\mathbf{X}$ sont **linéairement dépendantes**, alors il existe des vecteurs non nuls $\mathbf{v} \neq \mathbf{0}$ tel que :

$$\mathbf{X}\mathbf{v} = \mathbf{0}.$$

Explication Intuitive : $\mathbf{X}^\top \mathbf{X}$ Mal Conditionnée Implique une Amplification de la Variance des Coefficients $\hat{\boldsymbol{\beta}}$

$\mathbf{X}^\top\mathbf{X}$ Mal conditionnée $\Rightarrow$ Amplification de Var($\hat{\boldsymbol{\beta}}$)

- L'estimateur des moindres carrés ordinaires des coefficients est donné par :
$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$$
- Sa variance est :
$$\text{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}$$
- Où $\sigma^2 = \text{Var}(\epsilon)$ est la variance de l'erreur.
- Si $\mathbf{X}^\top\mathbf{X}$ est mal conditionnée (i.e., proche d'être singulière), son inverse contiendra des valeurs élevées, amplifiant ainsi la variance des coefficients.

Facteur d'Inflation de la Variance (FIV)

Facteur d'Inflation de la Variance (FIV)

- Une mesure de la colinéarité est le Facteur d'Inflation de la Variance (FIV) (*Variance Inflation Factor (VIF)*) :

$$VIF_j = \frac{1}{1 - R_j^2}$$

- Où R_j^2 est le coefficient de détermination de la régression de la variable x_j sur les autres variables explicatives.
- Si R_j^2 est proche de 1, alors VIF_j est très grand, indiquant une forte colinéarité.
- Une règle empirique est que $VIF > 10$ signifie une colinéarité problématique.